

TRUY VẤN DỮ LIỆU


Bài 1. Truy vấn dựa trên so khớp từ

PGS.TS. Lê Thanh Hương
Trường Công nghệ thông tin và Truyền thông
Đại Học Bách Khoa Hà Nội

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Giải pháp truy vấn kiểu Boolean
5. Giải pháp không gian vec-tơ

1. Khái niệm Truy vấn dữ liệu

- Truy vấn dữ liệu (Data retrieval) là quá trình **trích xuất** những thông tin, dữ liệu cụ thể từ một nguồn **dữ liệu lớn** dựa trên **nhu cầu tìm kiếm** của người dùng.



1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Giải pháp truy vấn kiểu Boolean
5. Giải pháp không gian vec-tơ


2. Các dạng dữ liệu

- **Dữ liệu có cấu trúc**, tiêu biểu như CSDL quan hệ. Ví dụ câu query:
 - `SELECT * FROM business-catalogue WHERE category = florist AND city-zip = cb1`
- **Dữ liệu phi cấu trúc**: thiếu một cấu trúc chính thức, rõ ràng về mặt ngữ nghĩa và dễ dàng cho máy tính xử lý. Ví dụ: văn bản
- **Dữ liệu bán cấu trúc**: ví dụ HTML, XML...

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Giải pháp truy vấn kiểu Boolean
5. Giải pháp không gian vec-tơ

3. Một số bài toán truy vấn dữ liệu

- Tìm kiếm văn bản/đoạn văn bản
- Tìm kiếm đa ngôn ngữ (cross-lingual)



- Tìm kiếm trên dữ liệu có cấu trúc



3. Một số bài toán truy vấn dữ liệu

- Tìm kiếm đa thể thức (multimodal). Ví dụ:
 - Tìm các mẫu thiết kế
 - Tìm người/hình ảnh theo mô tả
 - Hỏi thông tin trên hình ảnh




Figure 1: Multi-Modal Knowledge Retrieval. Prior studies use multiple retrievers for separate purposes, while we retrieve knowledge through an end-to-end generative model.

3. Một số bài toán truy vấn dữ liệu

- Tìm kiếm đa thể thức. Ví dụ (tiếp):
 - Lúc em đăng ký môn NLP của GenAI thì bị lỗi này. Làm thế nào để xử lý?

[Thoát đăng nhập](#)



TRANG ĐĂNG KÝ LỚP HỌC

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI

♦ Mã sinh viên: [REDACTED]
♦ Họ tên SV: [REDACTED]
♦ Lớp: KS-GenAI (tạm thời)-K69
♦ Chương trình: GenAI
♦ Số tín chỉ tối đa: 24
♦ [Thông tin Danh sách lớp mở](#)

TRANG ĐĂNG KÝ SINH VIÊN

Đăng ký mã lớp: ĐK lớp

Chưa đủ điều kiện chọn học phần: Không được đăng ký học phần IT4772 do IT3160

Các lớp đăng ký

Mã lớp ↑	Mã lớp kèm	Tên lớp	Mã HP ↑	Loại lớp	TT lớp	Yêu cầu	Trạng thái ĐK	loại ĐK	Thực hiện	TC
156543	156543	Nhập môn Học máy và khai phá dữ liệu	IT3190	ĐA	Điều chỉnh đăng ký		Thành công	Online		3
152113	152113	Nền tảng AI tạo sinh	IT5410	LT+BT	Điều chỉnh đăng ký		Thành công	Online		3
152114	152114	Truy vấn dữ liệu	IT5411	LT+BT	Điều chỉnh đăng ký		Thành công	Online		2
152115	152115	Mô hình ngôn ngữ lớn	IT5412	LT+BT	Điều chỉnh đăng ký		Thành công	Online		3
152116	152116	Mô hình tạo sinh hình ảnh và video	IT5413	LT+BT	Điều chỉnh đăng ký		Thành công	Online		3
152117	152117	Vận hành hệ thống học máy	IT5414	LT+BT	Điều chỉnh đăng ký		Thành công	Online		2



ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Giải pháp truy vấn kiểu Boolean
5. Giải pháp không gian vec-tơ

4.1. Giải pháp Boolean

- Tìm những vở kịch của *Shakespeare* chứa các từ *Brutus* VÀ *Caesar* nhưng KHÔNG chứa từ *Calpurnia*?
- Có thể lấy tất cả các vở kịch của *Shakespeare* chứa *Brutus* và *Caesar*, sau đó loại bỏ các vở có chứa *Calpurnia*?
- Tại sao cách đó không tốt?
 - Chậm (đối với corpora lớn)
 - NOT *Calpurnia* không dễ
 - Các vấn đề khác (ví dụ: tìm từ *Romans* đứng gần *countrymen*) không khả thi
 - Xếp hạng kết quả truy vấn

Ma trận thuật ngữ - tài liệu (term-document matrices)

Doc. Term	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	1	1	0	0	0	1
Brutus	1	1	0	1	0	0
Caesar	1	1	0	1	1	1
Calpurnia	0	1	0	0	0	0
Cleopatra	1	0	0	0	0	0
mercy	1	0	1	1	1	1
worser	1	0	1	1	1	0

Brutus AND Caesar BUT NOT Calpurnia

Vecto biểu diễn sự xuất hiện thuật ngữ

- Với mỗi **thuật ngữ**, ta có 1 vectơ 0/1.
- Để thực hiện truy vấn, lấy các vectơ có chứa ***Brutus, Caesar*** và NOT ***Calpurnia*** → bitwise AND.
- 110100 AND
- 110111 AND
- 101111
- **100100**

Doc. Term	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	1	1	0	0	0	1
Brutus	1	1	0	1	0	0
Caesar	1	1	0	1	1	1
Calpurnia	0	1	0	0	0	0
Cleopatra	1	0	0	0	0	0
mercy	1	0	1	1	1	1
worser	1	0	1	1	1	0

Với bộ dữ liệu lớn hơn

- Xét $N = 1$ triệu tài liệu, mỗi tài liệu có 1000 từ.
 - Trung bình 6 bytes/từ bao gồm dấu cách/chấm
 - 6GB để lưu tài liệu
 - Có $M = 500K$ các thuật ngữ khác nhau trong các tài liệu đó
 - Không thể xây dựng ma trận vì quá lớn và quá thưa
- Sử dụng danh mục chỉ mục đảo (Inverted Index)

Chỉ mục ngược (Inverted index)


- Với mỗi thuật ngữ t , lưu danh sách các tài liệu chứa t
 - Mỗi tài liệu được xác định bởi **docID**

<i>Brutus</i>	⇒	<table><tr><td>1</td><td>2</td><td>4</td><td>11</td><td>31</td><td>45</td><td>173</td><td>174</td></tr></table>	1	2	4	11	31	45	173	174
1	2	4	11	31	45	173	174			
<i>Caesar</i>	⇒	<table><tr><td>1</td><td>2</td><td>4</td><td>5</td><td>6</td><td>16</td><td>57</td><td>132</td></tr></table>	1	2	4	5	6	16	57	132
1	2	4	5	6	16	57	132			
<i>Calpurnia</i>	⇒	<table><tr><td>2</td><td>31</td><td>54</td><td>101</td><td></td><td></td><td></td><td></td></tr></table>	2	31	54	101				
2	31	54	101							


Nếu từ **Caesar** được thêm vào tài liệu 14 thì sao?

Chỉ mục ngược

- Sử dụng danh sách kết nối động hoặc mảng có độ dài thay đổi



Xây dựng bảng chỉ mục ngược



Các bước đánh chỉ mục

- Tạo các bộ (từ, docID)

Doc 1

I did enact Julius
Caesar I was killed
i' the Capitol;
Brutus killed me.

Doc 2

So let it be with
Caesar. The noble
Brutus hath told you
Caesar was ambitious



Term	docID
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

Các bước đánh chỉ mục

- Sắp xếp theo từ, rồi theo docID

Term	docID	Term	docID
I	1	ambitious	2
did	1	be	2
enact	1	brutus	1
julius	1	brutus	2
caesar	1	capitol	1
I	1	caesar	1
was	1	caesar	2
killed	1	caesar	2
i'	1	did	1
the	1	enact	1
capitol	1	hath	1
brutus	1	I	1
killed	1	I	1
me	1	i'	1
so	2	it	2
let	2	julius	1
it	2	killed	1
be	2	killed	1
with	2	let	2
caesar	2	me	1
the	2	noble	2
noble	2	so	2
brutus	2	the	1
hath	2	the	2
told	2	told	2
you	2	you	2
caesar	2	was	1
was	2	was	2
ambitious	2	with	2



- Tạo từ điển. Mỗi từ trong từ điển đi kèm tổng số tài liệu chứa từ và posting list lưu list các tài liệu chứa từ. Posting list sắp theo docID

term	doc. freq.	→	postings lists
ambitious	1	→	2
be	1	→	2
brutus	2	→	1 → 2
capitol	1	→	1
caesar	2	→	1 → 2
did	1	→	1
enact	1	→	1
hath	1	→	2
i	1	→	1
i'	1	→	1
it	1	→	2
julius	1	→	1
killed	1	→	1
let	1	→	2
me	1	→	1
noble	1	→	2
so	1	→	2
the	2	→	1 → 2
told	1	→	2
you	1	→	2
was	2	→	1 → 2
with	1	→	2

Triển khai hệ thống Truy vấn dữ liệu


- Làm thế nào để lập chỉ mục hiệu quả?
 - Chúng ta cần bao nhiêu dung lượng lưu trữ?
- Liên quan đến:
- Số lượng thuật ngữ
 - Inverted index
 - Cấu trúc dữ liệu

Xử lý truy vấn : AND

- Xét truy vấn:


- Brutus AND Caesar***

- Định vị ***Brutus*** trong từ điển
 - Lấy posting list tương ứng.
 - Định vị ***Caesar*** trong từ điển;
 - Lấy posting list tương ứng.
 - Lấy giao của 2 posting list.



Phép trộn

- Duyệt qua 2 danh sách, thời gian tỉ lệ với số nút
 - Nếu 2 danh sách có độ dài là x và y , phép trộn có độ phức tạp $O(x+y)$.
 - Vấn đề cốt yếu: các danh sách sắp theo docID



Thuật toán lấy giao của 2 posting list

INTERSECT(p_1, p_2)


```
1  answer  $\leftarrow \langle \rangle$ 
2  while  $p_1 \neq \text{NIL}$  and  $p_2 \neq \text{NIL}$ 
3  do if  $\text{docID}(p_1) = \text{docID}(p_2)$ 
4      then ADD(answer,  $\text{docID}(p_1)$ )
5           $p_1 \leftarrow \text{next}(p_1)$ 
6           $p_2 \leftarrow \text{next}(p_2)$ 
7      else if  $\text{docID}(p_1) < \text{docID}(p_2)$ 
8          then  $p_1 \leftarrow \text{next}(p_1)$ 
9          else  $p_2 \leftarrow \text{next}(p_2)$ 
10 return answer
```

Câu truy vấn logic: so khớp

- Mô hình phản hồi Boolean có thể trả lời câu truy vấn ở dạng biểu thức Boolean
 - Câu truy vấn sử dụng *AND*, *OR* và *NOT* để kết nối các thuật ngữ
 - Coi mỗi tài liệu là 1 tập các từ
 - Chính xác: tài liệu thỏa điều kiện hoặc không
 - Đây là mô hình IR đơn giản nhất

Tối ưu hóa truy vấn


- Đây là trật tự tốt nhất để xử lý truy vấn?
- Xét 1 câu truy vấn là phép AND của n thuật ngữ
- Với mỗi thuật ngữ, lấy danh sách của nó , sau đó làm phép AND.



Query: **Brutus AND Calpurnia AND Caesar**

Tối ưu hóa truy vấn – Ví dụ

- Xử lý theo trật tự tăng của tần suất:
 - *khởi đầu với tập nhỏ, sau đó tiếp tục loại bỏ*



Thực hiện câu truy vấn (***Calpurnia AND Brutus***) ***AND Caesar***.

Cho các văn bản sau:

- **Doc1:** [Lập trình Hướng đối tượng với C++]
- **Doc2:** [Xây dựng dịch vụ Web với C++]
- **Doc3:** [Kiến trúc nguyên khối và kiến trúc dịch vụ nhỏ]
- **Doc4:** [Kiến trúc hệ thống thông tin]

a) Vẽ biểu diễn chỉ mục ngược;

b) Các văn bản nào sẽ được trả về cho truy vấn:

- Lập trình AND C++
- Xây dựng AND (Dịch vụ OR Hệ thống)

1. Khái niệm Truy vấn dữ liệu
2. Các dạng dữ liệu
3. Một số bài toán truy vấn dữ liệu
4. Giải pháp truy vấn kiểu Boolean
5. Giải pháp không gian vec-tơ

5. Giải pháp không gian vec-tơ

5.1. Trọng số từ

5.2. Mô hình không gian vec-tơ

5.3. Các phiên bản của trọng số tf-idf

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

5.5. Các thành phần của hệ thống tìm kiếm thông tin

5.6. So sánh các hình thức truy vấn đã học

5.1. Trọng số từ

- Đánh giá độ tương đồng văn bản-truy vấn:
 - Nếu từ trong câu truy vấn xuất hiện nhiều trong văn bản thì độ tương đồng của từ với văn bản được đánh giá càng cao.
- Một số đặc trưng tiêu biểu
 - Tần suất xuất hiện của từ trong văn bản (Term frequency)
 - Số văn bản chứa từ (Document frequency)
 - Độ dài văn bản (số từ trong văn bản có ảnh hưởng tới 2 đặc trưng đầu tiên).

- Tần suất từ - **Term frequency**.
- $tf_{t,d}$: Số lần xuất hiện của từ t trong văn bản d
- Ví dụ cho văn bản $d1$ có nội dung:
 - Sách bán chạy nhất năm_nay là sách của anh_ấy

$$tf_{\text{sách}, d1} = 2$$

- Tần suất văn bản - **Document frequency**
- df_t : số văn bản trong tập văn bản có chứa từ t .
- Ví dụ cho tập văn bản D:
 - d1: Ngôn ngữ lập trình C++
 - d2: Lập trình hướng đối tượng với C++
 - d3: Ngôn ngữ lập trình CTừ C++ xuất hiện trong 2 văn bản, vì vậy $df_{C++} = 2$.
- Nghịch đảo tần suất văn bản - **Invert Document Frequency** :
 - $idf(t, D) = \log_e(N / df_t)$
 - với N : Số văn bản trong tập D

- $tf.idf(t, d, D) = tf(t, d) * idf(t, D)$
- Những từ có tf.idf cao là những từ xuất hiện nhiều trong 1 văn bản này và xuất hiện ít trong văn bản khác. Việc này giúp lọc ra những từ phổ biến và giữ lại những từ có giá trị cao trong văn bản (keyword).

5.1. Trọng số từ

5.2. Mô hình không gian vec-tơ

5.3. Các phiên bản của trọng số tf-idf

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

5.5. Các thành phần của hệ thống tìm kiếm thông tin

5.6. So sánh các hình thức truy vấn đã học

5.2. Mô hình không gian vec-tơ

Biểu diễn truy vấn như vec-tơ

- Coi mỗi từ chỉ mục là một trục của không gian vec-tơ
 - Không gian vec-tơ thu được có số chiều rất lớn
 - Số chiều $M = |V|$ = bằng kích thước bộ từ vựng
 - M có thể lên tới hàng chục triệu với tập văn bản lớn.
- Biểu diễn văn bản
 - Mỗi văn bản là một vec-tơ M chiều, với mỗi chiều ứng với trọng số 1 từ
 - Vec-tơ thưa (hầu hết các thành phần = 0).
 - Mỗi văn bản là một điểm trong không gian vec-tơ

Mô hình không gian vec-tơ / Vector Space Model (VSM)

Biểu diễn truy vấn như vec-tơ

- Câu truy vấn được biểu diễn như 1 vec-tơ trong cùng không gian biểu diễn văn bản
- Độ tương đồng giữa văn bản với truy vấn được tính dựa trên:
 - Khoảng cách giữa các điểm;
 - Góc tạo bởi các vec-tơ.
 - V.V..


Các văn bản trong danh sách kết quả tìm kiếm được sắp xếp theo thứ tự giảm dần độ tương đồng với truy vấn.

Mô phỏng độ tương đồng trong VSM

- Thử nghiệm đầu tiên: Đo khoảng cách giữa các điểm
- Khoảng cách Euclid?
 - Các văn bản có độ dài khác nhau thường có khoảng cách Euclid lớn;
 - Trong thực tế độ dài của truy vấn thường ngắn hơn nhiều so với văn bản
 - Nếu lặp nội dung văn bản nhiều lần, thì độ dài vec-tơ tăng lên nhưng nội dung vẫn không thay đổi

Khoảng cách Euclide ít được sử dụng trong tìm kiếm và có thể cho kết quả không tốt như trong trường hợp các văn bản có khác biệt về độ dài.

Ví dụ 1. Khoảng cách Euclid



Văn bản d_2 có phân bố từ vựng giống với q nhất nhưng xa truy vấn q nhất, khoảng cách Euclid giữa $\vec{d}_2$ và $\vec{q}$ lớn nhất vì vậy d_2 bị xếp hạng thấp nhất.

Tuy nhiên có thể thấy góc giữa $\vec{d}_2$ và $\vec{q}$ là nhỏ nhất.


Thử nghiệm 1 : Khoảng cách góc

- Thử lấy một văn bản d và lặp nội dung của nó nhiều lần, chúng ta ký hiệu văn bản thu được là d'
- Về mặt ý nghĩa thì d và d' tương đương
 - Khoảng cách Euclid giữa $\vec{d}$ và $\vec{d}'$ có thể rất lớn.
 - Nhưng góc giữa hai vec-tơ $\vec{d}$ và $\vec{d}'$ bằng 0 - tương ứng với khoảng cách tối thiểu.

Khoảng cách góc có thể mô phỏng độ tương đồng tốt hơn khoảng cách Euclidean trong VSM

Góc và cosine

- Cosine là hàm đơn điệu giảm trong khoảng $[0^\circ, 180^\circ]$
- Vì vậy hai lựa chọn sau là tương đương:
 - Sắp xếp các văn bản theo thứ tự **tăng dần góc** tạo bởi các biểu diễn vec-tơ của văn bản truy vấn
 - Sắp xếp các văn bản theo thứ tự **giảm dần cosine** góc tạo bởi các biểu diễn vec-tơ của văn bản và truy vấn




Tuy nhiên tính cosine thuận tiện và đơn giản hơn tính góc

Độ tương đồng cosine

- Cosine của góc tạo bởi vec-tơ văn bản và vec-tơ truy vấn:
 - Nghịch biến so với khoảng cách góc và được gọi là độ tương đồng cosine
 - Bằng tích vô hướng chia cho tích độ dài của các vec-tơ

$$\text{Sim}_{\cos}(d, q) = \frac{\vec{d} \cdot \vec{q}}{\|\vec{d}\| \cdot \|\vec{q}\|} = \frac{\sum_{i=1}^{|V|} (w_{i,d} \cdot w_{i,q})}{\sqrt{\sum_{i=1}^{|V|} w_{i,d}^2} \cdot \sqrt{\sum_{i=1}^{|V|} w_{i,q}^2}}$$



Ví dụ:

$$\vec{d}_1 = 2\vec{t}_1 + 3\vec{t}_2 + 5\vec{t}_3$$

$$\vec{d}_2 = 3\vec{t}_1 + 7\vec{t}_2 + 1\vec{t}_3$$

$$\vec{q} = 0\vec{t}_1 + 0\vec{t}_2 + 2\vec{t}_3$$

$$\begin{aligned} \text{Sim}_{\cos}(\vec{d}_1, \vec{q}) &= 10 / \sqrt{(4+9+25)(0+0+4)} = \\ 0.81 \quad \text{Sim}_{\cos}(\vec{d}_2, \vec{q}) &= 2 / \sqrt{(9+49+1)(0+0+4)} = \\ &= 0.13 \end{aligned}$$

=> d_1 phù hợp với truy vấn q hơn so với d_2 .

Chuẩn hóa cosine


- Chuẩn hóa vec-tơ bằng cách chia vec-tơ cho độ dài của nó. Đại lượng chuẩn hóa cosine:

$$1/||\vec{x}|| = 1/\sqrt{\sum_i x_i^2}$$

- Các hệ quả:
 - Độ dài vec-tơ sau chuẩn hóa cosine = 1. Mỗi văn bản có thể được coi như một điểm trên bề mặt siêu cầu có bán kính = 1 (sau khi chuẩn hóa biểu diễn vec-tơ);
 - Cosine góc của các vec-tơ bằng tích vô hướng của các vec-tơ đó sau khi chuẩn hóa cosine.
 - => Cosine là một trường hợp đặc biệt của tích vô hướng.

Chuẩn hóa cosine làm giảm sự khác biệt khoảng cách Euclidean của các văn bản ngắn và văn bản dài tới truy vấn.

Ví dụ 2. Chuẩn hóa cosine



Đối với các vec-tơ đã chuẩn hóa: Thứ tự xếp hạng theo khoảng cách góc tương đương với thứ tự xếp hạng theo khoảng cách Euclid.

5.1. Trọng số từ

5.2. Mô hình không gian vec-tơ

5.3. Các phiên bản của trọng số tf-idf

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

5.5. Các thành phần của hệ thống tìm kiếm thông tin

5.6. So sánh các hình thức truy vấn đã học

5.3. Các phiên bản của trọng số tf-idf

- SMART – System for the Mechanical Analysis and Retrieval of Text - là một dự án nghiên cứu TKTT dựa trên nền tảng đại số
 - Thử nghiệm nhiều công thức tính độ tương đồng

Term frequency		Document frequency		Normalization	
n (natural)	$tf_{t,d}$	n (no)	1	n (none)	1
l (logarithm)	$1 + \log(tf_{t,d})$	t (idf)	$\log \frac{N}{df_t}$	c (cosine)	$\frac{1}{\sqrt{w_1^2 + w_2^2 + \dots + w_M^2}}$
a (augmented)	$0.5 + \frac{0.5 \times tf_{t,d}}{\max_t(tf_{t,d})}$	p (prob idf)	$\max\{0, \log \frac{N - df_t}{df_t}\}$	u (pivoted unique)	$1/u$
b (boolean)	$\begin{cases} 1 & \text{if } tf_{t,d} > 0 \\ 0 & \text{otherwise} \end{cases}$			b (byte size)	$1/CharLength^\alpha$, $\alpha < 1$
L (log ave)	$\frac{1 + \log(tf_{t,d})}{1 + \log(\text{ave}_{t \in d}(tf_{t,d}))}$				


Các chữ cái trong bảng là các ký hiệu cho các công thức được sử dụng để tính độ tương đồng.

Tính độ tương đồng trong hệ SMART

- Trong hệ ký hiệu SMART, một công thức tính độ tương đồng được mô tả bằng một bộ 6 ký tự theo định dạng ddd.qqq
 - *(Các chữ cái d, q trong mô tả chỉ là đại diện cho các ký tự tương ứng với các công thức sẽ được áp dụng cho văn bản và truy vấn).*
 - Ba ký tự đầu tiên mô tả các công thức được áp dụng cho văn bản (để tính và chuẩn hóa biểu diễn vec-tơ).
 - Ba ký tự tiếp theo mô tả các công thức được áp dụng cho truy vấn.
 - Độ tương đồng được tính bằng tích vô hướng của các vec-tơ thu được sau khi áp dụng các công thức.

Term frequency		Document frequency		Normalization	
n (natural)	$tf_{t,d}$	n (no)	1	n (none)	1
l (logarithm)	$1 + \log(tf_{t,d})$	t (idf)	$\log \frac{N}{df_t}$	c (cosine)	$\frac{1}{\sqrt{w_1^2 + w_2^2 + \dots + w_M^2}}$
a (augmented)	$0.5 + \frac{0.5 \times tf_{t,d}}{\max_t(tf_{t,d})}$	p (prob idf)	$\max\{0, \log \frac{N - df_t}{df_t}\}$	u (pivoted unique)	$1/u$
b (boolean)	$\begin{cases} 1 & \text{if } tf_{t,d} > 0 \\ 0 & \text{otherwise} \end{cases}$			b (byte size)	$1/CharLength^\alpha$, $\alpha < 1$
L (log ave)	$\frac{1 + \log(tf_{t,d})}{1 + \log(\text{ave}_{t \in d}(tf_{t,d}))}$				

- Đối với truy vấn: sử dụng log tf, idf, và chuẩn hóa cosine



Ví dụ 4. Độ tương đồng theo Inc.Itc

Sử dụng các dữ liệu:

- Văn bản: Bảo hiểm ô tô bảo hiểm xe máy
- Truy vấn: Bảo hiểm ô tô tốt nhất

Từ chỉ mục	Văn bản				Truy vấn						Tích
	tf	w_{tf}	w	norm	tf	w_{tf}	df	idf	w	norm	
xe máy	1				0		5000	2.3			
tốt nhất	0				1		50000	1.3			
ô tô	1				1		10000	2.0			
bảo hiểm	2				1		1000	3.0			

Dựa trên các giá trị df và idf hãy xác định N

Hãy điền đủ các giá trị vào các cột đang còn trống

Ví dụ 4. Độ tương đồng theo Inc.ltc₍₂₎

Sử dụng các dữ liệu:

- Văn bản: Bảo hiểm ô tô bảo hiểm xe máy
- Truy vấn: Bảo hiểm ô tô tốt nhất

Từ chỉ mục	Văn bản				Truy vấn						Tích
	tf	w _{tf}	w	norm	tf	w _{tf}	df	idf	w	norm	
xe máy	1	1	1	0.52	0	0	5000	2.3	0	0	0
tốt nhất	0	0	0	0	1	1	50000	1.3	1.3	0.34	0
ô tô	1	1	1	0.52	1	1	10000	2.0	2.0	0.52	0.27
bảo hiểm	2	1.3	1.3	0.68	1	1	1000	3.0	3.0	0.78	0.53

$$|d^{\rightarrow}| = \sqrt{1^2 + 0^2 + 1^2 + 1.3^2} \approx 1,92$$

$$|q^{\rightarrow}| = \sqrt{1,3^2 + 0^2 + 2,0^2 + 3,0^2} \approx 3,83$$

$$RSV(d, q) = d^{\rightarrow}_{\text{norm}} \cdot q^{\rightarrow}_{\text{norm}} = 0 + 0 + 0.27 + 0.53 = 0.8$$

Ví dụ 5. Độ tương đồng theo Inc.ltn

Sử dụng các dữ liệu:

- Văn bản: Bảo hiểm ô tô bảo hiểm xe máy tốt nhất
- Truy vấn: Bảo hiểm ô tô tốt nhất

Từ chỉ mục	Văn bản				Truy vấn						Tích
	tf	w_{tf}	w	norm	tf	w_{tf}	df	idf	w	norm	
xe máy	1				0		5000	2.3			
tốt nhất	1				1		50000	1.3			
ô tô	1				1		10000	2.0			
bảo hiểm	2				1		1000	3.0			
Tổng:											

Hãy điền đủ các giá trị vào các ô đang còn trống

Ví dụ 5. Độ tương đồng theo Inc.ltn

Sử dụng các dữ liệu:

- Văn bản: Bảo hiểm ô tô bảo hiểm xe máy tốt nhất
- Truy vấn: Bảo hiểm ô tô tốt nhất

Từ chỉ mục	Văn bản				Truy vấn						Tích
	tf	w _{tf}	w	norm	tf	w _{tf}	df	idf	w	norm	
xe máy	1	1	1	0.46	0 0		5000	2.3	0	0	0
tốt nhất	1	1	1	0.46	1 1		50000	1.3	1.3	1.3	0.6
ô tô	1	1	1	0.46	1 1		10000	2.0	2	2	0.92
bảo hiểm	2	1.3	1.3	0.6	1 1		1000	3.0	3	3	1.8
Tổng:											3.32

Hãy điền đủ các giá trị vào các ô đang còn trống

$$||d|| = \sqrt{3 + 1.3 * 1.3} = 2.17$$

5.1. Trọng số từ

5.2. Mô hình không gian vec-tơ

5.3. Các phiên bản của trọng số tf-idf

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

5.5. Các thành phần của hệ thống tìm kiếm thông tin

5.6. So sánh các hình thức truy vấn đã học

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

Vấn đề thời gian xử lý truy vấn


- Các danh sách thể định vị có thể rất dài
 - Làm sao để giữ tốc độ phản hồi nhanh?
 - Liệu có thể bỏ qua (không tính cosine cho) một số văn bản?

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

Một số lựa chọn:

- **Chỉ xét các từ truy vấn có idf cao**
 - Cơ sở: Từ có idf nhỏ ít ảnh hưởng tới độ tương đồng;
 - Lợi ích: Từ có idf nhỏ có danh sách thể định vị dài, loại bỏ từ có idf nhỏ giúp giảm đáng kể thời gian xử lý truy vấn.
- **Chỉ xét các văn bản có chứa nhiều từ truy vấn**
 - Cơ sở: Văn bản có chứa nhiều từ truy vấn có nhiều khả năng là văn bản phù hợp.
 - Điều kiện áp dụng: Trong điều kiện có thể xử lý từng văn bản và truy vấn chứa nhiều từ.
 - Lợi ích: Giảm được số trường hợp cần tính độ tương đồng.

Ví dụ 6. Lọc từ truy vấn



Nếu chỉ xét các văn bản có chứa tối thiểu 70% số lượng từ truy vấn, thì chúng ta chỉ cần tính độ tương đồng cho các văn bản 8, 16 và 32.

Các đại lượng tĩnh

- Tính phù hợp có thể được tính theo VSM cho văn bản theo từng truy vấn.
- Bên cạnh đó cũng có những đại lượng thể hiện chất lượng văn bản độc lập với truy vấn, chúng ta gọi đó là các đại lượng tĩnh.
- Ví dụ một số đại lượng tĩnh:
 - Có liên kết từ Wikipedia
 - Là bài viết thuộc tạp chí uy tín
 - Có nhiều trích dẫn
 - PageRank
- Giả sử chúng ta có thể tính được đại lượng tĩnh thể hiện chất lượng của các văn bản, ký hiệu là $g(d)$.

Độc lập với truy vấn.

Kết hợp các thành phần

- Có thể kết hợp độ tương đồng và đại lượng chất lượng tĩnh bằng một công thức tuyến tính đơn giản:
- $RSV(d, q) = \text{net-score}(d, q) = g(d) + \text{sim}(q, d)$,
 - trong đó $g(d)$ và $\text{sim}(q, d)$ được chuẩn hóa về cùng miền giá trị.
- Cả hai đại lượng đều thể hiện khả năng đáp ứng nhu cầu thông tin của người dùng
- *Có thể sử dụng bất kỳ hàm kết hợp tuyến tính nào khác.*

Thu hẹp phạm vi tìm kiếm dựa trên $g(d)$


- Ý tưởng: Sắp xếp các thẻ định vị theo $g(d)$
 - Vẫn có thể đảm bảo trật tự ổn định cho cả thẻ định vị và thực hiện xử lý từng văn bản.
- Lợi ích: Các văn bản có điểm xếp hạng cao có thể ở đầu danh sách => Có thể dừng xử lý sớm
 - Ví dụ, giới hạn xử lý trong 50 ms.

Phân cấp chỉ mục

- Với mỗi từ chỉ mục, chúng ta duy trì hai danh sách thể định vị, gọi là danh sách cao và danh sách thấp
 - Tách các danh sách theo ngưỡng tf.
 - Danh sách cao chứa những thể định vị có tf lớn.
 - Danh sách thấp chứa những thể định vị còn lại.
 - Như vậy chúng ta sẽ có 2 chỉ mục.
 - *Có nên chia thành nhiều cấp hơn hay không?*
- Khi xử lý truy vấn danh sách cao được duyệt trước:
 - Nếu đã tìm đủ top-K văn bản, thì dừng tiến trình duyệt
 - Nếu ngược lại thì tiếp tục tìm kiếm trong danh sách thấp

Chúng ta cũng có thể tách danh sách theo số lượng thể định vị

Ví dụ 7. Phân cấp chỉ mục



Thử tìm top 3 cho truy vấn t1 t3 trong 2 trường hợp:

- Giới hạn tìm kiếm trong chỉ mục cấp cao.
- Tìm kiếm trong toàn bộ chỉ mục (Không giới hạn).

Sắp xếp thể định vị theo ảnh hưởng

- Chúng ta cũng có thể sắp xếp thể định vị **theo trọng số**, ví dụ $tf_{t,d}$:
 - Lợi ích: Các văn bản có trọng số cao đứng đầu danh sách
 - => Có thể chủ động ngắt sớm
 - Ví dụ: có thể ngắt sau khi hết giới hạn thời gian, hoặc trọng số giảm xuống nhỏ hơn ngưỡng.
 - Tuy nhiên: Không có trật tự ổn định giữa các thể định vị => Không thể xử lý từng văn bản:
 - Độ tương đồng của văn bản khi ngắt sớm có thể là giá trị gần đúng.
 - Cần duy trì giá trị tích lũy của các văn bản trong tiến trình xử lý.

Giản lược tìm kiếm dựa trên chia cụm

Tổ chức chỉ mục:


- Chia bộ văn bản được sử dụng để tìm kiếm thành b_1 cụm và xác định trọng tâm cho các cụm.
- Tạo chỉ mục riêng cho từng cụm $\Rightarrow$ Chúng ta thu được cấu trúc chỉ mục phân tán theo văn bản.

Xử lý truy vấn:

- Cho truy vấn q , tìm b_2 **trọng tâm** gần nhất.
- Tìm top K trong phạm vi các cụm tương ứng với b_2 trọng tâm tìm được.


Giới hạn tìm kiếm dựa trên phân cụm vẫn có thể bỏ qua kết quả phù hợp; b_1 và b_2 là các tham số tùy chỉnh.

Ví dụ 8. Tìm kiếm trong phạm vi cụm



Lấy tâm cụm ngẫu nhiên: Nhanh và phản ánh được phân bố dữ liệu.

Kiến trúc tổng quan của máy tìm kiếm



5.1. Trọng số từ

5.2. Mô hình không gian vec-tơ

5.3. Các phiên bản của trọng số tf-idf

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

5.5. Các thành phần của hệ thống tìm kiếm thông tin

5.6. So sánh các hình thức truy vấn đã học

- Truy vấn dạng văn bản do người dùng cung cấp có thể kéo theo một hoặc nhiều truy vấn được xử lý bên trong hệ thống, ví dụ, truy vấn: Tăng trưởng kinh tế có thể kéo theo:
 - Thực hiện truy vấn như truy vấn nguyên câu
 - Nếu có ít hơn K văn bản có chứa nguyên đoạn "Tăng trưởng kinh tế" thì chạy hai truy vấn: Tăng trưởng và Kinh tế
 - Xếp hạng các văn bản tìm được theo VSM
 - v.v...
- Các kết quả thực hiện các truy vấn thành phần sau đó được tổng hợp lại thành kết quả thực hiện truy vấn ban đầu.

Tổng hợp điểm và học máy

- Các hàm tính điểm có thể kết hợp các thành phần cosine, đại lượng tĩnh, v.v., và sử dụng các tham số.
- Làm sao để xác định các giá trị tham số tốt nhất?
 - Trong một trường hợp được thiết lập bởi chuyên gia
 - ... Trong (có thể là phần lớn) các trường hợp còn lại được thiết lập bằng các phương pháp học máy

Mô-đun học máy cung cấp các bộ tham số được sử dụng để tính điểm và xếp hạng.

5.1. Trọng số từ

5.2. Mô hình không gian vec-tơ

5.3. Các phiên bản của trọng số tf-idf

5.4. Các kỹ thuật thu hẹp phạm vi tìm kiếm

5.5. Các thành phần của hệ thống tìm kiếm thông tin

5.6. So sánh các hình thức truy vấn đã học

Truy vấn trong VSM và mô hình Boolean

- Trong VSM, thông tin được diễn đạt như văn bản, không chứa các toán tử lô-gic, vì vậy đơn giản hơn so với truy vấn Boolean
 - Truy vấn dạng văn bản (như trong VSM) hiện nay cũng là hình thức truy vấn được sử dụng phổ biến nhất.
 - Truy vấn nguyên câu và các liên kết lô-gic vẫn được hỗ trợ cùng với truy vấn dạng văn bản, nhưng ít phổ biến hơn.
- Trong VSM, câu truy vấn được tách thành tập từ truy vấn, các văn bản chứa nhiều từ truy vấn có thể có độ tương đồng cao hơn các văn bản có chứa ít từ truy vấn vì vậy có nhiều khả năng được trả về hơn => Tương tự như liên kết AND được ngầm định và ưu tiên cao hơn liên kết OR.

Bài tập 1

Cho các dữ liệu thống kê tf và df như sau:

tf(t, d)	Doc1	Doc2	Doc3
xe máy	27	4	24
tốt nhất	3	33	0
ô tô	0	33	29
bảo hiểm	14	0	17

t	df	idf
xe máy	18 165	
tốt nhất	6 723	
ô tô	19 241	
bảo hiểm	25 235	

Cho $N = 800\ 000$

- Hãy tính ma trận trọng số tf.idf
- Xếp hạng các văn bản theo truy vấn "bảo hiểm ô tô tốt nhất" dựa trên sơ đồ nnn.atc

Bài tập 2

Giả sử các đại lượng chất lượng tĩnh xác định được cho các văn bản d1, d2, d3 lần lượt là 0.25, 0.5 và 1. Hãy vẽ chỉ mục ngược với các thẻ định vị được sắp xếp theo $g(d) + tf_{\text{norm}}(t, d)$. Biết rằng:

tf ở dạng thô			
	d1	d2	d3
t1	27	4	24
t2	3	33	0
t3	0	33	29
t4	14	0	17

tf đã chuẩn hóa cosine			
	d1	d2	d3
t1	0.88		
t2	0.10		
t3	0		
t4	0.46		

Có thứ tự ổn định trong trường hợp này hay không?

Trong trường hợp phân cấp chỉ mục, đối với các truy vấn nhiều từ chúng ta cần các thẻ định vị với độ dài tối thiểu là bao nhiêu trong cấp đầu tiên để có thể lấy đủ top K văn bản?

Vấn đề láng giềng gần nhất trên mặt phẳng có thể phát biểu như sau: Cho N điểm trên mặt phẳng, và một điểm tương ứng với truy vấn q . Chúng ta cần tìm K điểm (ví dụ $K = 3$) gần với q nhất trong N điểm.

Để tránh tính khoảng cách từ q đến tất cả các điểm còn lại có thể áp dụng phương pháp thu hẹp phạm vi tìm kiếm dựa trên phân cụm.

Hãy lấy một phản ví dụ với hai cụm sao cho phương pháp thu hẹp phạm vi tìm kiếm trả về kết quả sai/khác với kết quả vét cạn (bỏ qua một số điểm gần hơn).

Bài tập 5

Cho bộ dữ liệu văn bản gồm các văn bản sau:

d1: a b e g a

d2: b b f h b

d3: f g h h a g h

d4: a g b c c a c c c

d5: b f g g a g

d6: a e f f e e f e a e e

- a) Hãy vẽ chỉ mục ngược có chứa tf (mã văn bản tăng dần).
- b) Hãy tách chỉ mục thu được ở mục a thành 2 cấp, trong đó chỉ mục ở cấp 1 chỉ chứa các thẻ định vị với $tf > 2$, chỉ mục ở cấp 2 chứa tất cả các thẻ định vị còn lại.
- c) Hãy thử tính kết quả xử lý truy vấn a c e trong 2 trường hợp: 1) chỉ tìm kiếm ở chỉ mục cấp 1; 2) tìm kiếm đầy đủ ở cả 2 cấp; sau đó kiểm tra xem có nào trong 2 trường hợp hay không?