

TRUY VẤN DỮ LIỆU

Bài 3. Tìm kiếm thông tin dựa trên xác suất

PGS.TS. Lê Thanh Hương
Trường Công nghệ thông tin và Truyền thông
Đại học Bách Khoa Hà Nội

1. Căn bản lý thuyết xác suất
2. Nguyên lý xếp hạng xác suất
3. Mô hình nhị phân độc lập
4. Mô hình Okapi BM25

Một số từ viết tắt

Từ	Ý nghĩa	Viết tắt
Probability Ranking Principle	Nguyên lý xếp hạng xác suất	PRP
Binary Independence Model	Mô hình nhị phân độc lập	BIM
Retrieval Status Value	Giá trị trạng thái truy vấn	RSV
Best Match 25	Kết quả tốt nhất trong 25 phiên bản	BM25
Odd	Tỷ lệ cược	O

Cách tiếp cận xác suất cho tìm kiếm thông tin

1. Cho câu truy vấn (**query**) và một tập tài liệu (**document**), hệ thống cần xác định mức độ liên quan của tài liệu với truy vấn
2. Hệ thống tìm kiếm hiểu không chắc chắn về câu query, và dự đoán (không chắc chắn) về mức độ liên quan của một tài liệu
3. Lý thuyết xác suất cung cấp nguyên lý cơ bản cho việc lập luận dựa trên sự không chắc chắn đó
4. Các mô hình xác suất dựa trên nguyên lý này để đánh giá mức độ liên quan của 1 tài liệu với truy vấn

Ôn lại lý thuyết xác suất cơ bản

- Cho các sự kiện A và B
 - $P(A, B)$ hoặc $P(AB)$: Xác suất xuất hiện đồng thời cả 2 sự kiện A và B
 - $P(A|B)$: Xác suất A xuất hiện khi có B.
- Luật chuỗi Bayes:
$$P(A, B) = P(A|B)P(B) = P(B|A)P(A)$$
$$P(\bar{A}B) = P(B|\bar{A})P(\bar{A})$$
- Luật phân rã: Nếu B có thể được chia thành tập các sự kiện không giao nhau, thì $P(B)$ là tổng xác suất của các sự kiện đó.
 - Ví dụ: $B = (B \cap A) \cup (B \cap \bar{A}) \Rightarrow P(B) = P(B, A) + P(B, \bar{A})$

Ôn lại lý thuyết xác suất cơ bản₍₂₎

- Kết hợp luật Bayes và luật phân rã:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(B|A)}{\sum_{X \in \{A, \bar{A}\}} P(B|X)P(X)} \cdot P(A)$$

- Đây là cách để cập nhật xác suất:

- Bắt đầu với xác suất tiên nghiệm $P(A)$ (ước tính ban đầu về khả năng xảy ra sự kiện A khi không có bất kỳ thông tin nào khác)
- Suy ra xác suất hậu nghiệm $P(A|B)$ sau khi đã xem xét bằng chứng B , dựa trên khả năng xảy ra của B trong hai trường hợp A có hoặc không có.
- Tỷ lệ cược (odd) của một sự kiện đánh giá sự thay đổi của xác suất theo cấp số nhân:

$$\text{Odds: } O(A) = \frac{P(A)}{P(\bar{A})} = \frac{P(A)}{1 - P(A)}$$

1. Căn bản lý thuyết xác suất
2. Nguyên lý xếp hạng xác suất
3. Mô hình nhị phân độc lập
4. Mô hình Okapi BM25

Vấn đề xếp hạng tài liệu

1. Thiết lập xếp hạng truy vấn: cho tập tài liệu D và 1 truy vấn q , hệ thống trả về một danh sách các tài liệu d được sắp xếp thứ tự.
2. Đặt $R_{d,q}$ là mức độ liên quan dạng nhị phân
 - $R_{d,q} = 1$ nếu d có liên quan với q
 - $R_{d,q} = 0$ nếu ngược lại
3. Sắp xếp các tài liệu theo thứ tự giảm dần của xác suất ước tính về mức độ liên quan của d với q :
$$P(R = 1|d, q)$$
 - Giả thiết mức độ liên quan của mỗi tài liệu độc lập với mức độ liên quan của các tài liệu khác.

Nguyên lý xếp hạng xác suất (PRP)

- **Probability Ranking Principle (PRP)**
- PRP giản lược
 - Nếu các tài liệu được xếp hạng **theo thứ tự giảm dần xác suất** liên quan với câu truy vấn, thì hiệu quả của hệ thống sẽ là cao nhất
- PRP đầy đủ
 - Nếu kết quả tìm kiếm cho mỗi truy vấn là một danh sách các tài liệu được xếp hạng theo thứ tự **giảm dần xác suất** liên quan với truy vấn, trong đó **các giá trị xác suất đã được ước lượng chính xác nhất** có thể dựa trên tất cả những dữ liệu mà hệ thống có cho mục đích này, thì **lợi ích** mà người dùng nhận được từ hệ thống là **cực đại** trong phạm vi có thể đạt được dựa trên những dữ liệu đó.

Xếp hạng tài liệu theo xác suất

- Các tài liệu được xếp hạng theo thứ tự giảm dần xác suất liên quan với truy vấn (**Retrieval Status Value**):

$$RSV(d, q) = P(R=1|d, q)$$

Trong các công thức tiếp theo chúng ta thu gọn cách viết, mặc định R là $R = 1$, và $\bar{R}$ là $R = 0$.

1. Căn bản lý thuyết xác suất
2. Nguyên lý xếp hạng xác suất
3. Mô hình nhị phân độc lập
4. Mô hình Okapi BM25

Binary Independence Model (BIM)

- Mô hình nhị phân độc lập
- Các giả thuyết:
 - “Nhị phân”: Các tài liệu và truy vấn được biểu diễn như những vec-tơ đánh dấu sự xuất hiện của từ
 - Tài liệu được biểu diễn như vec-tơ $\vec{x} = (x_1, \dots, x_M)$;
 - Trong đó $x_i = 1$ nếu t_i xuất hiện trong d ; $x_i = 0$ nếu ngược lại; M là kích thước bộ từ vựng.
 - *!Lưu ý: Các tài liệu khác nhau có thể có cùng biểu diễn.*
 - Giả thiết “độc lập”: Sự xuất hiện của mỗi từ là độc lập với sự xuất hiện của các từ khác

Binary incidence matrix

	Anthony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth	...
ANTHONY	1	1	0	0	0	1	
BRUTUS	1	1	0	1	0	0	
CAESAR	1	1	0	1	1	1	
CALPURNIA	0	1	0	0	0	0	
CLEOPATRA	1	0	0	0	0	0	
MERCY	1	0	1	1	1	1	
WORSER	1	0	1	1	1	0	
...							

Mỗi tài liệu được biểu diễn dưới dạng vectơ nhị phân $\in \{0, 1\}^{|V|}$.

Binary Independence Model

- Để truy xuất xác suất chính xác, cần ước tính cách các thuật ngữ trong tài liệu đóng góp vào mức độ liên quan.
- Tìm các độ đo thống kê (tần suất thuật ngữ, tần suất tài liệu, độ dài tài liệu) ảnh hưởng đến đánh giá về mức độ liên quan của tài liệu.
- Kết hợp các độ đo này để ước tính xác suất $P(R|d, q)$ về mức độ liên quan của tài liệu.

Xếp hạng trong BIM

- $P(R|d, q)$ được mô hình hóa bằng vec-tơ $P(R|\vec{x}, \vec{q})$

$$P(R = 1|\vec{x}, \vec{q}) = \frac{P(\vec{x}|R = 1, \vec{q})P(R = 1|\vec{q})}{P(\vec{x}|\vec{q})}$$

$$P(R = 0|\vec{x}, \vec{q}) = \frac{P(\vec{x}|R = 0, \vec{q})P(R = 0|\vec{q})}{P(\vec{x}|\vec{q})}$$

- $P(\vec{x} | R=1, \vec{q})$ và $P(\vec{x} | R=0, \vec{q})$: xác suất tài liệu liên quan và không liên quan được trả về
- Sử dụng số liệu thống kê trong tập tài liệu để tính các xác suất này

- $P(R|d, q)$ được mô hình hóa bằng vec-tơ $P(R|\vec{x}, \vec{q})$

$$P(R = 1|\vec{x}, \vec{q}) = \frac{P(\vec{x}|R = 1, \vec{q})P(R = 1|\vec{q})}{P(\vec{x}|\vec{q})}$$

$$P(R = 0|\vec{x}, \vec{q}) = \frac{P(\vec{x}|R = 0, \vec{q})P(R = 0|\vec{q})}{P(\vec{x}|\vec{q})}$$

$$P(R = 1|\vec{x}, \vec{q}) + P(R = 0|\vec{x}, \vec{q}) = 1$$

- $P(R=1|\vec{q})$ và $P(R=0|\vec{q})$: xác suất tiên nghiệm cho các trường hợp tài liệu liên quan và không liên quan với truy vấn q .
 - Có thể ước lượng dựa trên tỉ lệ tài liệu liên quan có trong bộ dữ liệu, dữ liệu lịch sử, hoặc đơn giản là sử dụng giá trị đồng nhất, v.v..

Biến đổi hàm xếp hạng

- Trong tìm kiếm thông tin người dùng chỉ quan tâm thứ tự tương đối giữa các tài liệu
 - Có thể sử dụng Odd $O(R|d, q)$ thay thế cho $P(R|d, q)$.
- Áp dụng luật Bayes cho các thành phần trong Odd:

$$O(R|\vec{x}, \vec{q}) = \frac{P(R = 1|\vec{x}, \vec{q})}{P(R = 0|\vec{x}, \vec{q})} = \frac{\frac{P(R=1|\vec{q})P(\vec{x}|R=1,\vec{q})}{P(\vec{x}|\vec{q})}}{\frac{P(R=0|\vec{q})P(\vec{x}|R=0,\vec{q})}{P(\vec{x}|\vec{q})}}$$

Hằng số đối với 1 truy vấn,
=> Có thể lược bỏ.

$$= \frac{P(R = 1|\vec{q})}{P(R = 0|\vec{q})} \cdot \frac{P(\vec{x}|R = 1, \vec{q})}{P(\vec{x}|R = 0, \vec{q})}$$

- Áp dụng giả thiết độc lập

$$\Rightarrow O(R|\vec{x}, \vec{q}) = O(R|\vec{q}) \cdot \prod_{t=1}^M \frac{P(x_t|R = 1, \vec{q})}{P(x_t|R = 0, \vec{q})}$$

Biến đổi hàm xếp hạng₍₂₎

Vì x_t chỉ có thể nhận giá trị 0 hoặc 1, chúng ta có thể tách chuỗi tích thành 2 thành phần:

$$O(R|\vec{x}, \vec{q}) = O(R|\vec{q}) \cdot \prod_{t: x_t=1} \frac{P(x_t = 1|R = 1, \vec{q})}{P(x_t = 1|R = 0, \vec{q})} \cdot \prod_{t: x_t=0} \frac{P(x_t = 0|R = 1, \vec{q})}{P(x_t = 0|R = 0, \vec{q})}$$

- Đặt $p_t = P(x_t = 1|R=1, \vec{q})$: xác suất từ xuất hiện trong tài liệu liên quan
- Đặt $u_t = P(x_t = 1|R=0, \vec{q})$: xác suất từ xuất hiện trong tài liệu không liên quan

Ta có các giá trị xác suất:

Tài liệu	Liên quan ($R = 1$)	Không liên quan ($R = 0$)
Từ có xuất hiện $x_t = 1$	p_t	u_t
Từ không xuất hiện $x_t = 0$	$1 - p_t$	$1 - u_t$

Biến đổi hàm xếp hạng (3)

Giả sử các từ không có trong truy vấn có khả năng xảy ra như nhau trong các tài liệu có liên quan và không liên quan - Nếu $q_t = 0$ thì $p_t = u_t$.

$$O(R|\vec{x}, \vec{q}) = O(R|\vec{q}) \cdot \prod_{t:x_t=1} \frac{P(x_t = 1|R = 1, \vec{q})}{P(x_t = 1|R = 0, \vec{q})} \cdot \prod_{t:x_t=0} \frac{P(x_t = 0|R = 1, \vec{q})}{P(x_t = 0|R = 0, \vec{q})}$$

$$O(R|\vec{x}, \vec{q}) = O(R|\vec{q}) \cdot \prod_{t:x_t=q_t=1} \frac{p_t}{u_t} \cdot \prod_{t:x_t=0, q_t=1} \frac{1 - p_t}{1 - u_t}$$

Biến đổi hàm xếp hạng (3)

$$O(R|\vec{x}, \vec{q}) = O(R|\vec{q}) \cdot \prod_{t: x_t=q_t=1} \frac{p_t}{u_t} \cdot \prod_{t: x_t=0, q_t=1} \frac{1-p_t}{1-u_t}$$

$$\begin{aligned} O(R|\vec{x}, \vec{q}) &= O(R|\vec{q}) \cdot \prod_{t: x_t=q_t=1} \frac{p_t}{u_t} \cdot \prod_{t: x_t=q_t=1} \frac{1-u_t}{1-p_t} \cdot \frac{1-p_t}{1-u_t} \cdot \prod_{\substack{t: x_t=0 \\ q_t=1}} \frac{1-p_t}{1-u_t} \\ &= O(R|\vec{q}) \cdot \prod_{t: x_t=q_t=1} \frac{p_t(1-u_t)}{u_t(1-p_t)} \cdot \prod_{t: q_t=1} \frac{1-p_t}{1-u_t} \end{aligned}$$

Biến đổi hàm xếp hạng (3)

$$\begin{aligned} O(R|\vec{x}, \vec{q}) &= O(R|\vec{q}) \cdot \prod_{t:x_t=q_t=1} \frac{p_t}{u_t} \cdot \prod_{t:x_t=q_t=1} \frac{1-u_t}{1-p_t} \cdot \frac{1-p_t}{1-u_t} \cdot \prod_{\substack{t:x_t=0 \\ q_t=1}} \frac{1-p_t}{1-u_t} \\ &= O(R|\vec{q}) \cdot \prod_{t:x_t=q_t=1} \frac{p_t(1-u_t)}{u_t(1-p_t)} \cdot \prod_{t:q_t=1} \frac{1-p_t}{1-u_t} \end{aligned}$$

- Bên trái của phép nhân là các từ truy vấn được tìm thấy trong tài liệu,
- Bên phải phép nhân là trên tất cả các từ truy vấn $\rightarrow$ không thay đổi đối với một truy vấn cụ thể và có thể được bỏ qua.
- Lượng duy nhất cần được ước lượng để xếp hạng tài liệu theo truy vấn là phép nhân bên trái.

Hàm giá trị trạng thái tìm kiếm

$$RSV(d, q) = \log \prod_{t: x_t = q_t = 1} \frac{p_t(1-u_t)}{u_t(1-p_t)}$$

$$RSV(d, q) = \sum_{t: x_t = q_t = 1} \log \frac{p_t(1-u_t)}{u_t(1-p_t)}$$

Đặt $c_t = \log \frac{p_t(1-u_t)}{u_t(1-p_t)}$

Chúng ta có: $RSV(d, q) = \sum_{t: x_t = q_t = 1} c_t$

c_t có vai trò tương tự trọng số từ và được tích lũy vào giá trị trạng thái tìm kiếm của tài liệu.

$$c_t = \log \frac{p_t(1-u_t)}{u_t(1-p_t)}$$

- Trọng số c_t về bản chất là tỉ lệ của 2 tỉ lệ:
 - tỉ lệ từ xuất hiện trong tài liệu liên quan $p_t/(1-p_t)$,
 - tỉ lệ từ xuất hiện trong tài liệu không liên quan $u_t/(1-u_t)$.
- $c_t = 0$ Nếu các tỉ lệ bằng nhau;
- $c_t > 0$ Nếu tỉ lệ xuất hiện trong tài liệu liên quan cao hơn.
- $c_t < 0$ Trong trường hợp còn lại (tỉ lệ xuất hiện trong tài liệu liên quan nhỏ hơn).

Ước lượng các giá trị xác suất

1. Với mỗi term t trong truy vấn q , tính c_t trong tập dữ liệu sử dụng thông tin số tài liệu trong tập đó, với df_t là số tài liệu chứa thuật ngữ t

	documents	relevant	nonrelevant	Total
Term present	$x_t = 1$	s	$df_t - s$	df_t
Term absent	$x_t = 0$	$S - s$	$(N - df_t) - (S - s)$	$N - df_t$
Total		S	$N - S$	N

$$p_t = s/S \quad u_t = (df_t - s)/(N - S) \quad c_t = \log \frac{p_t(1-u_t)}{u_t(1-p_t)}$$

$$c_t = K(N, df_t, S, s) = \log \frac{s/(S - s)}{(df_t - s)/((N - df_t) - (S - s))}$$

Làm mịn trọng số BIM

- Nếu bất kỳ số đếm nào bằng không, thì trọng số của thuật ngữ không xác định.
- Để tránh giá trị bằng không: thêm 0,5 vào mỗi thừa số
- Ví dụ, sử dụng $S - s + 0,5$ trong công thức cho $S - s$.

Trong trường hợp số tài liệu liên quan rất nhỏ:

- Xác suất xuất hiện của thuật ngữ trong các tài liệu không liên quan $u_t = df_t/N$

$$\log[(1 - u_t)/u_t] = \log[(N - df_t)/df_t] \approx \log N/df_t$$

- Công thức này giống idf
- Xác suất xuất hiện của thuật ngữ trong các tài liệu liên quan p_t có thể $+0.5$

Điểm khác nhau giữa vector space và BIM?

- Không quá khác
- Trong cả hai trường hợp, hệ thống được xây dựng theo cách hoàn toàn giống nhau.
- Đối với truy xuất thông tin theo xác suất, các truy vấn được tính điểm không phải bằng độ tương đồng cosine và tf-idf trong không gian vector, mà bằng một công thức hơi khác, dựa trên lý thuyết xác suất.
- Làm cách nào để thêm tần suất xuất hiện từ và chuẩn hóa độ dài vào mô hình xác suất?

- Độ chính xác không cao
 - BIM - Được thiết kế để tìm kiếm tài liệu ngắn (tiêu đề hoặc tóm tắt) và số lượng tài liệu không quá nhiều.
 - Với biểu diễn dạng vec-tơ nhị phân nhiều tài liệu khác nhau có thể có cùng biểu diễn.
 - Không thực hiện được với tìm kiếm với các tài liệu dài và số lượng tài liệu lớn.
- Để xếp hạng tốt hơn chúng ta cần sử dụng tần suất từ và độ dài tài liệu

1. Căn bản lý thuyết xác suất
2. Nguyên lý xếp hạng xác suất
3. Mô hình nhị phân độc lập
4. Mô hình Okapi BM25

- BM25 - Best Match 25 (kết quả tốt nhất trong 25 phiên bản)
 - Được phát triển trong hệ thống Okapi
 - Được sử dụng phổ biến
 - Hiệu quả hơn độ tương đồng cosine
- Ngoài thành phần tương tự BIM, BM25 còn sử dụng tần suất từ và độ dài tài liệu với các tham số điều chỉnh.

Các phiên bản đầu tiên của BM25

- Phiên bản 1: Sử dụng hàm bão hòa

$$c_i^{BM25v1}(tf_i) = c_i^{BIM} \frac{tf_i}{k_1 + tf_i}$$

- Phiên bản 2: Giảm lược BIM thành IDF và tăng giá trị cho thành phần tf.

$$c_i^{BM25v2}(tf_i) = \log \frac{N}{df_i} \times \frac{(k_1 + 1)tf_i}{k_1 + tf_i}$$

- Thành phần $k_1 + 1$ không làm thay đổi xếp hạng, nhưng khiến thành phần chứa tf_i bằng 1 khi $tf_i = 1$

Tương tự tf-idf, nhưng trọng số bị giới hạn.

- Các tài liệu dài có xu hướng có giá trị tf_i lớn
- Vì sao tài liệu có thể dài hơn?
 - Quá chi tiết: Cho rằng tf_i quan sát được quá lớn
 - Phạm vi rộng hơn.
- Một tập tài liệu thực có thể có cả 2 trường hợp
- ... vì vậy cần chuẩn hóa

- Chúng ta ký hiệu độ dài tài liệu là:

$$dl = \sum_{i \in V} tf_i$$

- avdl: Trung bình độ dài tài liệu trên toàn tập tài liệu
- Thành phần chuẩn hóa độ dài

$$B = \left((1 - b) + b \frac{dl}{avdl} \right), \quad 0 \leq b \leq 1$$

- $b = 1$ chuẩn hóa với toàn bộ độ dài tài liệu
- $b = 0$ không chuẩn hóa độ dài tài liệu

- Chuẩn hóa tf sử dụng độ dài tài liệu

$$tf'_i = \frac{tf_i}{B}$$

$$\begin{aligned} c_i^{BM25}(tf_i) &= \log \frac{N}{df_i} \times \frac{(k_1 + 1)tf'_i}{k_1 + tf'_i} \\ &= \log \frac{N}{df_i} \times \frac{(k_1 + 1)tf_i}{k_1((1 - b) + b \frac{dl}{avdl}) + tf_i} \end{aligned}$$

- Hàm giá trị trạng thái tìm kiếm BM25

$$RSV^{BM25} = \sum_{i \in q} c_i^{BM25}(tf_i);$$

$$RSV^{BM25} = \sum_{i \in q} \log \frac{N}{df_i} \cdot \frac{(k_1 + 1)tf_i}{k_1((1 - b) + b \frac{dl}{avdl}) + tf_i}$$

- k_1 Điều khiển thành phần tần suất tài liệu
 - $k_1 = 0$ là mô hình nhị phân; k_1 lớn là tần suất từ ở dạng thô.
- b điều khiển chuẩn hóa độ dài tài liệu
 - $b = 0$ là không chuẩn hóa độ dài; $b = 1$ là tần suất tương đối (hiệu chỉnh hoàn toàn bằng độ dài tài liệu)
- Thông thường, k_1 được thiết lập trong khoảng 1.2-2 và b thường được thiết lập = 0.75

- Với các truy vấn dài, sử dụng trọng số tương tự cho các thuật ngữ truy vấn

$$RSV_d = \sum_{t \in q} \left[\log \frac{N}{df_t} \right] \cdot \frac{(k_1 + 1)tf_{td}}{k_1((1 - b) + b \times (L_d/L_{ave})) + tf_{td}} \cdot \frac{(k_3 + 1)tf_{tq}}{k_3 + tf_{tq}}$$

- tf_{tq} : term frequency trong query q
- k_3 : tham số điều khiển thành phần trọng số từ truy vấn.
- $k_3 = 0$ - mô hình nhị phân, thành phần trọng số truy vấn không làm ảnh hưởng tới kết quả xếp hạng.
- k_3 rất lớn - tf ở dạng thô.

Ví dụ 1. BM25 và tf-idf

- Giả sử truy vấn của bạn là [học máy]
- Giả sử bạn có 2 tài liệu với số lượng từ (tf):
 - d1: học 1024; máy 1
 - d2: học 16; máy 8
- tf-idf: $(1 + \log_2 \text{tf}) * \log_2 (N/\text{df})$
 - doc1: $11 * 7 + 1 * 10 = 87$
 -
- BM25: $k_1 = 2$
 - doc1: $7 * 3 + 10 * 1 = 31$
 -

(Sử dụng $k_1 = 2$; $b = 0$)

Ví dụ 1. BM25 và tf-idf₍₂₎

- Giả sử truy vấn của bạn là [học máy]
- Giả sử bạn có 2 tài liệu với số lượng từ (tf):
 - d1: học 1024; máy 1
 - d2: học 16; máy 8
- tf-idf: $(1 + \log_2 \text{tf}) * \log_2 (N/\text{df})$
 - doc1: $11 * 7 + 1 * 10 = 87$
 - doc2: $5 * 7 + 4 * 10 = 75$
- BM25: $k_1 = 2$
 - doc1: $7 * 3 + 10 * 1 = 31$
 - doc2: $7 * 2.67 + 10 * 2.4 = 42.7$

(Sử dụng $k_1 = 2$; $b = 0$)