

TRUY VẤN DỮ LIỆU

Bài 6. Truy vấn dựa trên ngữ nghĩa Phần 2

PGS.TS. Lê Thanh Hương
Trường Công nghệ thông tin và Truyền thông
Đại học Bách Khoa Hà Nội

- Bi-Encoder (tiếp)
 - Contrastive learning
 - coCondenser
 - SimCSE
 - BGE_M3
- Mở rộng tài liệu với doc2query
- Hạn chế của Bi-Encoder
- Reranking
 - Neural Reranking
 - monoBERT reranker
 - CEDR: Reranking with contextualized embeddings
 - DeepCT
 - Graph-based Rerankers

Contrastive learning

- Contrastive Learning là một kỹ thuật học máy nhằm học vector embeddings sao cho các điểm dữ liệu tương tự nhau nằm gần nhau, còn các điểm dữ liệu không liên quan thì bị đẩy xa nhau.
- **Các mẫu dữ liệu:** là các cặp:
 - **Positive Pair:** Hai mẫu dữ liệu giống nhau hoặc có liên quan về ngữ nghĩa (ví dụ: cùng một câu với các phép biến đổi ngẫu nhiên, hoặc hai câu diễn tả nội dung tương tự).
 - **Negative Pair:** Hai mẫu dữ liệu không liên quan hoặc khác biệt về ngữ nghĩa.

- **Loss Function:**

- **Contrastive Loss:** Khoảng cách giữa các cặp positive được tối thiểu hóa, và khoảng cách giữa các cặp negative được tối đa hóa.
- **Triplet Loss:** Dựa trên ba mẫu (anchor, positive, negative) và tối ưu hóa sao cho positive gần anchor hơn negative.
- **InfoNCE Loss**(Information Noise-Contrastive Estimation Loss): Một dạng cross-entropy loss giúp tối ưu hóa việc phân biệt positive khỏi negative trong một batch lớn.

- **Data Augmentation:**

- Sinh thêm dữ liệu từ dữ liệu ban đầu mà vẫn giữ nguyên ý nghĩa. Ví dụ: loại bỏ từ, thay đổi cấu trúc câu, v.v.

- **Condenser** và **coCondenser** là hai mô hình tiền huấn luyện được thiết kế để cải thiện biểu diễn của văn bản trong các bài toán tìm kiếm (dense retrieval). Mặc dù cả hai đều nhằm mục đích tối ưu hóa khả năng mã hóa văn bản, chúng khác nhau về cách tiếp cận trong kiến trúc và quá trình tiền huấn luyện.
- **Condenser**: Mặc dù đã cải thiện khả năng mã hóa văn bản so với BERT, Condenser chủ yếu tối ưu cho việc thu gọn thông tin (condensation) mà không hoàn toàn tối ưu cho dense retrieval trong mọi trường hợp.
- **coCondenser**: Với việc tích hợp contrastive learning, coCondenser cho thấy hiệu suất tốt hơn trong dense retrieval, đặc biệt là khi biểu diễn các câu và tài liệu với độ phân biệt cao hơn. Điều này làm cho coCondenser hiệu quả hơn cho các hệ thống tìm kiếm yêu cầu độ chính xác cao.

Izacard, Gautier, et al. "Unsupervised dense information retrieval with contrastive learning." *arXiv preprint arXiv:2112.09118* (2021).

- **Mẫu dương:** (câu hỏi, tài liệu), lấy từ các bộ có sẵn như MS MARCO.
- **Mẫu âm ngẫu nhiên:** chọn ngẫu nhiên từ tập dữ liệu mà không có quan hệ ngữ nghĩa với câu hỏi → giúp học cách phân biệt các tài liệu hoàn toàn không liên quan.
- **Học tương phản:** 1 mẫu học gồm (câu hỏi, 1 mẫu dương, 1 hay nhiều mẫu âm). Mô hình học cách tối đa hóa khoảng cách giữa các mẫu dương và mẫu âm
- **Loss function:** contrastive InfoNCE loss


$$\mathcal{L}(q, k_+) = - \frac{\exp(s(q, k_+)/\tau)}{\exp(s(q, k_+)/\tau) + \sum_{i=1}^K \exp(s(q, k_i)/\tau)}$$

- **Fine-tuning:** nén các biểu diễn của tài liệu và câu hỏi để giảm số chiều, giúp cải thiện cả độ chính xác và tốc độ tính toán

- **SimCSE (Simple Contrastive Learning of Sentence Embeddings)**
- **Ý tưởng:** huấn luyện để kéo các câu tương tự lại gần, đẩy những câu khác nhau ra xa nhau
- Pretrained embeddings + **Contrastive Learning** = SOTA sentence embeddings
 - **Unsupervised SimCSE:** sử dụng kỹ thuật **dropout** (bỏ một số neuron trong mạng) để tạo ra các câu giống nhau nhưng có sự khác biệt nhỏ trong biểu diễn.
 - **Supervised SimCSE:** các cặp câu giống nhau được lấy từ dữ liệu song ngữ hoặc từ các tập dữ liệu paraphrase
- **Mục tiêu:** cải thiện chất lượng biểu diễn ngữ nghĩa của câu, dựa trên các mô hình ngôn ngữ được huấn luyện trước như BERT, RoBERTa, và GPT

Gao, Tianyu, Xingcheng Yao, and Danqi Chen. "Simcse: Simple contrastive learning of sentence embeddings." *EMNLP* (2021).

- InfoNCE loss:



The diagram illustrates the InfoNCE loss formula with the following components and annotations:


- Similarity function:** An arrow points to the $\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)$ term in the numerator.
- Sentence embedding:** An arrow points to the $\mathbf{h}_i$ term in the numerator.
- Temperature:** An arrow points to the τ term in the denominator.
- Positive pairs:** A green arrow points to the numerator term $e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau}$.
- Negative pairs:** A red arrow points to the denominator term $e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_j^+)/\tau}$.

$$\ell_i = -\log \frac{e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau}}{\sum_{j=1}^N e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_j^+)/\tau}}$$

- Các mẫu dương và âm lấy ở đâu?
- Data augmentation

Unsupervised SimCSE

- Mẫu dương: các embedding của cùng 1 câu, sử dụng các dropout mask khác nhau, để ra các biểu diễn khác nhau $\rightarrow$ cặp câu tương đồng
- Mẫu âm: các embedding của các câu khác trong cùng 1 batch



$$\ell_i = -\log \frac{e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau}}{\sum_{j=1}^N e^{\text{sim}(\mathbf{h}_i, \mathbf{h}_j^+)/\tau}}$$

Supervised SimCSE

- Sử dụng dữ liệu có nhãn để cải thiện chất lượng biểu diễn. Các cặp câu giống nhau (positive pair) được lấy từ dữ liệu song ngữ hoặc từ các tập dữ liệu paraphrase (câu có nghĩa giống nhau).
- Mô hình học để phân biệt giữa các câu tương tự và không tương tự, dựa trên các nhãn có sẵn.
- **Loss function:** Thông thường sử dụng **cross-entropy loss** để tối ưu hóa sự khác biệt giữa các cặp câu có nhãn.

Given one premise,

- Premise: *There are two dogs running.*


Annotators are required to write hypotheses of

- Entailment: *There are animals outdoors.*
- Contradiction: *The pets are sitting on a couch.*
- Neutral: *The dogs are catching a ball.*

Positive pairs


Hard negatives

Supervised SimCSE



Unsupervised SimCSE

Semantic textual similarity (STS) tasks: Spearman's correlation




~10% higher than previous SOTA

~20% higher than avg. BERT embeddings

Supervised SimCSE

Semantic textual similarity (STS) tasks: Spearman's correlation



Even unsupervised SimCSE matches supervised SentenceBERT
6.7% higher than SentenceBERT using the same NLI datasets

Different unsupervised positive pairs

- SimCSE (dropout)

Compare it to

- Next sentence
- Synonym replacement
- Crop
- Delete one word

Different dropout

NLP is interesting. — NLP is interesting.

I do NLP. — NLP is interesting.


The movie is **great**. — The movie is **fantastic**.

~~Two dogs~~ **are running**. — ~~Two~~ **dogs are** ~~running~~.

Two dogs are **running**. — Two dogs **are** running.

Điểm khác biệt

Unsupervised SimCSE



Default setting: 1 million sentences randomly sampled from English Wikipedia, N=64, evaluated on STS-B development set (Spearman's correlation)

- Predicting sentence itself $\gg$ predicting next sentence
- Using dropout as data augmentation $\gg$ discrete data augmentation (!!)

- Hạn chế của các mô hình embedding:
 - Hầu hết chỉ hỗ trợ tiếng Anh
 - Thường được huấn luyện chỉ cho một chức năng truy xuất duy nhất. Tuy nhiên, các hệ thống truy xuất thông tin điển hình đòi hỏi kết hợp nhiều phương pháp truy xuất khác nhau.
 - Phần lớn chỉ hỗ trợ các đầu vào ngắn.
- BGE-M3:
 - Đa chức năng: Hỗ trợ truy xuất dữ liệu **cả ở dạng dày đặc và dạng thưa**
 - Độ dài đầu vào lên đến 8.192 token.
 - Đề xuất một khung huấn luyện mới sử dụng kỹ thuật tự chưng cất tri thức (self-knowledge distillation) và chiến lược huấn luyện theo batch hiệu quả.

Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*.

Datasets: Unsupervised and Supervised datasets

- Tạo dữ liệu tổng hợp (synthetic data) cho tác vụ truy xuất tài liệu dài, bổ sung dữ liệu tinh chỉnh đa ngôn ngữ (được gọi là MultiLongDoc).
- Lấy các bài viết dài từ Wikipedia, Wudao và mC4 → chọn ngẫu nhiên các đoạn từ đó.
- Sử dụng GPT-3.5 để tạo câu hỏi dựa trên các đoạn văn này.
- Dữ liệu tinh chỉnh bao gồm các cặp (câu hỏi, bài viết)

Data Source	Language	Size
Unsupervised Data		
MTP	EN, ZH	291.1M
S2ORC, Wikipeda	EN	48.3M
xP3, mC4, CC-News	Multi-Lingual	488.4M
NLLB, CCMatrix	Cross-Lingual	391.3M
CodeSearchNet	Text-Code	344.1K
Total	–	1.2B
Fine-tuning Data		
MS MARCO, HotpotQA, NQ, NLI, etc.	EN	1.1M
DuReader, T ² -Ranking, NLI-zh, etc.	ZH	386.6K
MIRACL, Mr.TyDi	Multi-Lingual	88.9K
MultiLongDoc	Multi-Lingual	41.4K

Table 1: Specification of training data.

Quá trình huấn luyện

- Pre-trained tiếp XLM-RoBERTa để làm mô hình nền tảng




Figure 2: Multi-stage training process of M3-Embedding with self-knowledge distillation.

Experimental Results

Model	Avg	ar	bn	en	es	fa	fi	fr	hi	id	ja	ko	ru	sw	te	th	zh	de	yo
Baselines (<i>Prior Work</i>)																			
BM25	31.9	39.5	48.2	26.7	7.7	28.7	45.8	11.5	35.0	29.7	31.2	37.1	25.6	35.1	38.3	49.1	17.5	12.0	56.1
mDPR	41.8	49.9	44.3	39.4	47.8	48.0	47.2	43.5	38.3	27.2	43.9	41.9	40.7	29.9	35.6	35.8	51.2	49.0	39.6
mContriever	43.1	52.5	50.1	36.4	41.8	21.5	60.2	31.4	28.6	39.2	42.4	48.3	39.1	56.0	52.8	51.7	41.0	40.8	41.5
mE5 _{large}	66.6	76.0	75.9	52.9	52.9	59.0	77.8	54.5	62.0	52.9	70.6	66.5	67.4	74.9	84.6	80.2	56.0	56.4	78.3
E5 _{mistral-7b}	63.4	73.3	70.3	57.3	52.2	52.1	74.7	55.2	52.1	52.7	66.8	61.8	67.7	68.4	73.9	74.0	54.0	54.1	79.7
OpenAI-3	54.9	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
M3-Embedding (<i>Our Work</i>)																			
Dense	69.2	78.4	80.0	56.9	56.1	60.9	78.6	58.3	59.5	56.1	72.8	69.9	70.1	78.7	86.2	82.6	62.7	56.7	81.8
Sparse	53.9	67.1	68.9	43.8	38.6	45.1	65.4	35.3	48.2	48.9	56.1	61.5	44.5	57.9	79.1	70.9	36.1	32.5	70.0
Multi-vec	70.5	79.6	81.0	59.3	57.8	62.0	80.1	59.4	61.5	58.3	74.5	71.2	71.2	79.1	87.9	83.0	63.7	58.0	82.4
Dense+Sparse	70.4	79.6	80.7	58.8	58.1	62.3	79.7	58.0	62.9	58.3	73.9	71.2	69.8	78.5	87.2	83.1	63.5	57.7	83.3
All	71.5	80.2	81.5	59.6	59.7	63.4	80.4	61.2	63.3	59.0	75.2	72.1	71.7	79.6	88.1	83.7	64.9	59.8	83.5

Table 1: **Multi-lingual retrieval performance on the MIRACL dev set** (measured by nDCG@10).


Experimental Results

	Max Length	Avg	ar	de	en	es	fr	hi	it	ja	ko	pt	ru	th	zh
<i>Baselines (Prior Work)</i>															
BM25	8192	53.6	45.1	52.6	57.0	78.0	75.7	43.7	70.9	36.2	25.7	82.6	61.3	33.6	34.6
mDPR	512	23.5	15.6	17.1	23.9	34.1	39.6	14.6	35.4	23.7	16.5	43.3	28.8	3.4	9.5
mContriever	512	31.0	25.4	24.2	28.7	44.6	50.3	17.2	43.2	27.3	23.6	56.6	37.7	9.0	15.3
mE5 _{large}	512	34.2	33.0	26.9	33.0	51.1	49.5	21.0	43.1	29.9	27.1	58.7	42.4	15.9	13.2
E5 _{mistral-7b}	8192	42.6	29.6	40.6	43.3	70.2	60.5	23.2	55.3	41.6	32.7	69.5	52.4	18.2	16.8
text-embedding-ada-002	8191	32.5	16.3	34.4	38.7	59.8	53.9	8.0	46.5	28.6	20.7	60.6	34.8	9.0	11.2
jina-embeddings-v2-base-en	8192	-	-	-	37.0	-	-	-	-	-	-	-	-	-	-
<i>M3-Embedding (Our Work)</i>															
Dense	8192	52.5	47.6	46.1	48.9	74.8	73.8	40.7	62.7	50.9	42.9	74.4	59.5	33.6	26.0
Sparse	8192	62.2	58.7	53.0	62.1	87.4	82.7	49.6	74.7	53.9	47.9	85.2	72.9	40.3	40.5
Multi-vec	8192	57.6	56.6	50.4	55.8	79.5	77.2	46.6	66.8	52.8	48.8	77.5	64.2	39.4	32.7
Dense+Sparse	8192	64.8	63.0	56.4	64.2	88.7	84.2	52.3	75.8	58.5	53.1	86.0	75.6	42.9	42.0
All	8192	65.0	64.7	57.9	63.8	86.8	83.9	52.2	75.5	60.1	55.7	85.4	73.8	44.7	40.0
<i>M3-w.o.long</i>															
Dense-w.o.long	8192	41.2	35.4	35.2	37.5	64.0	59.3	28.8	53.1	41.7	29.8	63.5	51.1	19.5	16.5
Dense-w.o.long (MCLS)	8192	45.0	37.9	43.3	41.2	67.7	64.6	32.0	55.8	43.4	33.1	67.8	52.8	27.2	18.2


Table 3: **Evaluation of multilingual long-doc retrieval on the MLDR test set** (measured by nDCG@10).

Document expansion: doc2query

Idea: **generate** possible queries from a given document,
then use them to **expand** the document




Supervised training:
pairs of <query, relevant document>



Nogueira, Yang, Lin, Cho. Document expansion by query prediction. 2019.

46
Source: Vaswani et al., 2017



Examples from MS MARCO

Input Document: July is the hottest month in Washington DC with an average temperature of 27C (80F) and the coldest is January at 4C (38F) with the most daily sunshine hours at 9 in July. The wettest month is May with an average of 100mm of rain.

Predicted Query: weather in washington dc
Target query: what is the temperature in washington

Excluding
stop-words:

☐ 69% copied

☐ 31% new

Input Document: The Delaware River flows through Philadelphia into the Delaware Bay. It flows through and aqueduct in the Roundout Reservoir and then flows through Philadelphia and New Jersey before emptying into the Delaware Bay.

Predicted Query: what river flows through delaware
Target Query: where does the delaware river start and end

Input Document: sex chromosome - (genetics) a chromosome that determines the sex of an individual; mammals normally have two sex chromosomes chromosome - a threadlike strand of DNA in the cell nucleus that carries the genes in a linear order; humans have 22 chromosome pairs plus two sex chromosomes.


Predicted Query: what is the relationship between genes and chromosomes
Target Query: which chromosome controls sex characteristics

Results: doc2query on MS MARCO


	MRR@10	R@1000
Original Document	.184	.853
+ Expansion New Words	.195	.907
+ Expansion Copied Words	.221	.893
+ Expansion Copied + New	.277	.944
Only Expansions (no original document)	.263	.927

Hạn chế của Bi-Encoder

- Bi-encoder tối ưu hóa tốc độ nhưng hy sinh độ chính xác
 - chỉ tính toán tương đồng cosine giữa các vector đã được mã hóa sẵn.
 - không nắm bắt được hoàn toàn các mối quan hệ ngữ nghĩa phức tạp giữa truy vấn và tài liệu
- Cross-encoder xem xét các ngữ cảnh, giúp xác định mức độ liên quan chi tiết hơn.
- Bi-encoder thường được dùng để lọc nhanh ra danh sách top-K tài liệu liên quan từ một tập dữ liệu lớn. Rerank giúp cải thiện độ chính xác của top-K này, đảm bảo rằng các tài liệu có liên quan nhất sẽ được xếp hạng cao hơn.




Re-ranking




Re-ranking

Methods that use relevance judgments to **learn** how to rank results

- **ML** approaches **learn to rank** based on hand-crafted features (e.g., BM25 score between Q and D, spam score for D, etc)
- **Neural** approaches learn improved **text representations** for ranking



Re-ranking



Source: Techniques for Interpretable Machine Learning. Du, Liu, Hu. Communications of the ACM. 2020.

$$score(D, Q) = \sum_{i=1}^{|Q|} IDF(q_i) * TF(q_i, D)$$

**Inverse Document
Frequency of query term
(collection stat)**

**Term Frequency of
 q in document D
(document stat)**

IDF defined as:

- $\log N/n_i$
- $\log (1 + N/n_i)$
- $\log (N - n_i)/n_i$
- ...

$$score(D, Q) = \sum_{i=1}^{|Q|} IDF(q_i) * TF(q_i, D)$$

**Inverse Document
Frequency of query term**

**Term Frequency of
 q in document D**

$N = \# \text{ docs}$ and $n_i = \# \text{ docs with term } q_i$

- $TF(q_i, D)$
- $1 + \log TF(q_i, D)$
- $0.5 + 0.5 [TF(q_i, D) / \max TF(D)]$
- ...

$$score(D, Q) = \sum_{i=1}^{|Q|} IDF(q_i) * TF(q_i, D)$$

Inverse Document
Frequency of query term

Term Frequency of
 q in document D

$$score(D, Q) = \sum_{i=1}^{|Q|} IDF(q_i) * TF(q_i, D)$$



Exact matching of
Q and D terms

Soft matching via embeddings


	living being	feline	human	gender	royalty	verb	plural
cat →	0.6	0.9	0.1	0.4	-0.7	-0.3	-0.2
kitten →	0.5	0.8	-0.1	0.2	-0.6	-0.5	-0.1
dog →	0.7	-0.1	0.4	0.3	-0.4	-0.1	-0.3
houses →	-0.8	-0.4	-0.5	0.1	-0.9	0.3	0.8

Neural approaches
represent words
as learned *vectors*

Source: <https://medium.com/@hari4om/word-embedding-d816f643140>

Soft matching via embeddings

Vector “*embedding*” allows comparisons of different terms



Source: <https://medium.com/@hari4om/word-embedding-d816f643140>

Neural Reranking

- Learning to Rank (LTR) là kỹ thuật nền tảng được sử dụng để huấn luyện các mô hình học sâu (như Cross-Encoder) trong nhiệm vụ reranking.
- Sử dụng học máy để học hàm xếp hạng (ranking function) $f(Q, D)$.
- Dữ liệu huấn luyện (như MS MARCO): các cặp truy vấn-tài liệu đã được gán nhãn mức độ phù hợp bởi con người

Các Mô Hình Học Xếp Hạng

- **Pointwise:**

- phân loại (dự đoán nhãn phù hợp 0/1) hoặc hồi qui (dự đoán điểm phù hợp)

- **Pairwise:**

- xem xét một cặp tài liệu (D_i, D_j) cùng lúc và học cách xác định tài liệu nào nên đứng trước

- **Listwise:**

- xử lý toàn bộ danh sách tài liệu và trực tiếp tối ưu hóa các chỉ số xếp hạng dựa trên danh sách (ví dụ: NDCG).

- Dữ liệu huấn luyện: các cặp (*query*, *document*).
- Mục tiêu: dự đoán điểm phù hợp $\hat{y}_i = f(q, d_i)$ gần với nhãn thực y_i .
- **Phân loại: Binary Cross-Entropy Loss**

$$\mathcal{L}_{\text{pointwise}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

- trong đó
 $y_i \in \{0, 1\}$ là nhãn phù hợp,
 $\hat{y}_i = \sigma(f(q, d_i))$ là xác suất dự đoán (qua sigmoid).
- **Hồi quy: Mean Squared Error (MSE)**

$$\mathcal{L}_{\text{pointwise}} = \frac{1}{N} \sum_{i=1}^N (y_i - f(q, d_i))^2$$

Pairwise

- Học cách so sánh **cặp tài liệu** (d_i, d_j) cho cùng một truy vấn q , sao cho nếu d_i có độ liên quan cao hơn d_j , thì $f(q, d_i) > f(q, d_j)$.
- **Pairwise Logistic Loss (RankNet Loss)**

$$\mathcal{L}_{\text{pairwise}} = - \sum_{(i,j)} [P_{ij} \log(\hat{P}_{ij}) + (1 - P_{ij}) \log(1 - \hat{P}_{ij})]$$

Với

$$\hat{P}_{ij} = \sigma(f(q, d_i) - f(q, d_j)) = \frac{1}{1 + e^{-(f(q, d_i) - f(q, d_j))}}$$

$$P_{ij} = \begin{cases} 1, & \text{nếu } y_i > y_j \\ 0, & \text{nếu } y_i < y_j \end{cases}$$

khuyến khích mô hình gán điểm cao hơn cho tài liệu có nhãn phù hợp hơn

- Tối ưu hóa trực tiếp thứ hạng của **toàn bộ danh sách tài liệu** cho mỗi truy vấn, thường nhắm đến các thước đo như NDCG, MAP, v.v.
- **LambdaRank / LambdaMART Loss**: không định nghĩa một hàm mất mát tường minh, mà **tính gradient (“lambda”)** cho từng cặp tài liệu dựa trên thay đổi trong **NDCG** khi hoán đổi vị trí hai tài liệu.


$$\lambda_{ij} = -\sigma \cdot \frac{1}{1 + e^{\sigma(s_i - s_j)}} \cdot |\Delta \text{NDCG}_{ij}|$$

- s_i, s_j : điểm dự đoán của tài liệu d_i, d_j ,
 - σ : hệ số điều chỉnh độ dốc,
 - ΔNDCG_{ij} : thay đổi của NDCG nếu hoán vị d_i và d_j .
- **LambdaMART** (kết hợp LambdaRank và Gradient Boosted Trees) dùng λ_{ij} để cập nhật trọng số cây trong quá trình boosting.


monoBERT reranker

We want:

$$s_i = P(\text{Relevant} = 1 | q, d_i)$$





CEDR: Reranking with contextualized embeddings



MacAvaney, Yates, Cohan, Goharian. CEDR: Contextualized Embeddings for Document Ranking. SIGIR 2019.

CEDR: Reranking with contextualized embeddings



MacAvaney, Yates, Cohan, Goharian. CEDR: Contextualized Embeddings for Document Ranking. SIGIR 2019.

Results: CEDR on Robust04


	Method	Input Representation	Robust04 nDCG@20
(1)	BM25	n/a	0.4140
(2)	Vanilla BERT	BERT (fine-tuned)	[B] 0.4541
(3a)	PACRR	GloVe	0.4043
(3b)	PACRR	BERT	0.4200
(3c)	PACRR	BERT (fine-tuned)	[BVG] 0.5135
(3d)	CEDR-PACRR	BERT (fine-tuned)	[BVG] 0.5150
(4a)	KNRM	GloVe	0.3871
(4b)	KNRM	BERT	[G] 0.4318
(4c)	KNRM	BERT (fine-tuned)	[BVG] 0.4858
(4d)	CEDR-KNRM	BERT (fine-tuned)	[BVG] 0.5381
(5a)	DRMM	GloVe	0.3040
(5b)	DRMM	BERT	0.3194
(5c)	DRMM	BERT (fine-tuned)	[G] 0.4135
(5d)	CEDR-DRMM	BERT (fine-tuned)	[BVG] 0.5259

MacAvaney, Yates, Cohan, Goharian. CEDR: Contextualized Embeddings for Document Ranking. SIGIR 2019.



Graph-based Rerankers (G-RAG)

- Sử dụng GNNs để mô hình hóa các mối quan hệ ngữ nghĩa và cấu trúc không chỉ giữa truy vấn và tài liệu mà còn **giữa các tài liệu được truy xuất với nhau**.
- **G-RAG sử dụng hai loại đồ thị để tái xếp hạng tài liệu:** Đồ thị Abstract Meaning Representation (AMR) được dùng làm đặc trưng cho đồ thị ở cấp độ tài liệu. Sau đó, đồ thị tài liệu được sử dụng để thực hiện việc tái xếp hạng các tài liệu.
- Việc đánh giá độ phù hợp tối ưu phải tính đến mối quan hệ tương đối và tổng thể của danh sách tài liệu



Graph-based Rerankers (G-RAG)

- Tích hợp Đặc Trưng Ngữ Nghĩa AMR làm Node Features

Để cung cấp thông tin ngữ nghĩa sâu cho GNN, G-RAG tích hợp AMR vào đặc trưng nút (node features) x_i của mỗi tài liệu p_i :

1. **Trích xuất Khái niệm Chính (Key Concept Extraction):** Vì hầu hết các biểu đồ AMR G_{qp_i} đều có nút "question", mô hình trích xuất các **đường đi nguồn đơn ngắn nhất (Shortest Single Source Paths - SSSPs)** bắt đầu từ nút "question" trong G_{qp_i} .
2. **Tạo Chuỗi Khái niệm (a_i):** Các khái niệm/nút dọc theo các SSSPs được trích xuất để tạo thành một chuỗi từ cô đọng, a_i . Chuỗi này đại diện cho sự liên kết ngữ nghĩa giữa truy vấn và tài liệu.
3. **Tạo Embedding (Node Feature x_i):** Chuỗi khái niệm AMR đã trích xuất (a_i) được nối với văn bản gốc của tài liệu (p_i), và sau đó được mã hóa bằng một bộ mã hóa (ví dụ: BERT, BGE, GTE) để tạo ra embedding/đặc trưng nút x_i :

$$x_i = \text{Encode}(\text{concat}(p_i, a_i))$$

Ma trận X gồm các vector x_i này đóng vai trò là đầu vào ban đầu cho mạng GNN.

Graph-based Rerankers (G-RAG)

- Mô hình GNN: Cơ chế truyền tin (message-passing) của GCN cho phép mỗi nút cập nhật biểu diễn của mình bằng cách thu thập thông tin từ các nút lân cận
 - Nhận biết được 1 tài liệu có thể là một phần của câu trả lời, ngay cả khi nó chỉ có sự liên kết yếu với truy vấn nhưng lại có sự liên kết mạnh với các tài liệu phù hợp khác.
- Sử dụng **pairwise ranking loss** để tối ưu hóa trực tiếp nhiệm vụ xếp hạng.
- G-RAG đạt hiệu suất tốt hơn đáng kể so với việc sử dụng các LLM chưa fine tune như PaLM 2 làm reranker.