

TRUY VẤN DỮ LIỆU

Bài 7. Sử dụng LLM trong truy vấn thông tin

PGS.TS. Lê Thanh Hương
Trưởng Công nghệ thông tin và Truyền thông
Đại học Bách Khoa Hà Nội

1. Biến đổi câu truy vấn
2. Sử dụng LLM cho tìm kiếm và xếp hạng lại
3. Cải thiện text embeddings với LLMs
4. LLM2VEC
5. NV-Embed
6. Các kỹ thuật RAG tiên tiến

1. Biến đổi câu truy vấn

Khái niệm	Mục tiêu	Vai trò
Mở rộng truy vấn	Thêm ngữ cảnh, từ đồng nghĩa.	Tăng Recall, tìm được nhiều tài liệu liên quan hơn.
Viết lại truy vấn	Làm rõ ý định, giải quyết sự mơ hồ/thiếu ngữ cảnh.	Tăng Precision của truy vấn gốc.
Công cụ	Prompt Engineering	Hướng dẫn LLM tạo ra các truy vấn phụ chất lượng cao.

Mở rộng truy vấn

- Mở rộng dựa trên ngữ cảnh: Yêu cầu LLM tạo ra các cụm từ/từ khóa liên quan mà truy vấn gốc còn thiếu.
- Prompt:
 - Bạn là một trợ lý tìm kiếm thông minh. Truy vấn của người dùng là: "[Q_{original}]". Dựa trên truy vấn này, hãy liệt kê 3 cụm từ/từ khóa liên quan nhất nhưng chưa có trong truy vấn gốc, mà người dùng có thể đang muốn tìm kiếm. Trả lời chỉ bằng danh sách các cụm từ, mỗi cụm trên một dòng.
- Ví dụ:
 - Q_{original} : "chip M3"
 - LLM Output:
 - Apple Silicon
 - MacBook Pro hiệu năng
 - So sánh A17 Bionic

Mở rộng truy vấn

- Mở rộng bằng tài liệu giả định:
 - Yêu cầu LLM tạo một đoạn văn bản giả định chứa câu trả lời.
 - Sử dụng vector nhúng của đoạn văn giả định thay vì vector của truy vấn ngắn để tìm kiếm.
- Prompt:
 - Bạn là một chuyên gia về công nghệ. Truy vấn của người dùng là: "[Q_{original}]". Dựa trên kiến thức của bạn, hãy viết một đoạn văn (khoảng 2-3 câu) có chứa câu trả lời đầy đủ và chính xác cho truy vấn này. Đoạn văn này chỉ dùng để giúp tìm kiếm tài liệu.
- Ví dụ:
 - Q_{original} : "Các lợi ích của việc chạy bộ 30 phút mỗi ngày"
 - LLM Output (tài liệu giả định): "Chạy bộ 30 phút mỗi ngày là một hoạt động cardio tuyệt vời, giúp cải thiện sức khỏe tim mạch, tăng cường sức bền phổi và đốt cháy calo hiệu quả. Nó cũng góp phần giảm căng thẳng, cải thiện chất lượng giấc ngủ và ổn định tâm trạng."

Viết lại truy vấn


- Chuyển đổi truy vấn hội thoại sang độc lập: trong chatbot, truy vấn mới có thể thiếu ngữ cảnh từ các câu trước.
 - LLM viết lại truy vấn để nó có thể đứng độc lập
- Prompt:
 - Đây là lịch sử hội thoại:
[Lịch sử 3-5 lượt trò chuyện trước]
Truy vấn mới nhất của người dùng là: "[Q_{original}]".
Hãy viết lại truy vấn mới này thành một truy vấn đầy đủ, có thể tự đứng độc lập mà không cần ngữ cảnh trước đó.
- Ví dụ:
 - Lịch sử: User: "Giá của iPhone 15 là bao nhiêu?" - Bot: "Giá khởi điểm là 20 triệu VND."
 - Q_{original}: "Thế còn bản Pro Max thì sao?"
 - LLM Output: "Giá bán của iPhone 15 Pro Max là bao nhiêu?"

Viết lại truy vấn

- Tách truy vấn phức hợp: Khi truy vấn bao gồm nhiều yêu cầu hoặc câu hỏi, LLM phân tách chúng thành các truy vấn con, đơn giản hơn.
- Prompt:

Truy vấn của người dùng là: “ Q_{original} ”. Nếu truy vấn này chứa nhiều câu hỏi hoặc yêu cầu, hãy tách nó thành danh sách các truy vấn con đơn giản, độc lập.
- Ví dụ:
 - Q_{original} : “Khu vực Tây Nguyên có những tỉnh nào và loại cà phê phổ biến nhất là gì?”
 - LLM Output:
 - Các tỉnh thuộc khu vực Tây Nguyên
 - Loại cà phê nào phổ biến nhất ở Tây Nguyên

2. Sử dụng LLM cho tìm kiếm và xếp hạng lại




Two-stage retrieval pipeline: 1) Top-k embedding retrieval, then 2) LLM-based reranking

2. Sử dụng LLM cho tìm kiếm và xếp hạng lại

- Zero-Shot/Few-Shot Scoring: Yêu cầu LLM đánh giá mức độ liên quan của từng đoạn văn bản.
- Prompt Engineering:
 - Zero-Shot: "Hãy đánh giá mức độ liên quan của đoạn văn sau với truy vấn '[Q]'. Trả lời bằng một điểm số từ 1 (không liên quan) đến 5 (rất liên quan)."
 - Few-Shot: Cung cấp vài ví dụ về các cặp (Q, D) đã được đánh giá điểm trước đó để hướng dẫn LLM.

Sử dụng LLM cho xếp hạng lại

- **Listwise Re-ranking**



Dưới đây là câu hỏi và danh sách các tài liệu. Mỗi tài liệu được đánh số và có kèm phần tóm tắt nội dung. Nhiệm vụ của bạn là chọn ra những tài liệu có liên quan nhất để trả lời câu hỏi, sắp xếp theo relevance score giảm dần, và ghi kèm relevance score .

Relevance score có giá trị trong khoảng 1–10, cho biết mức độ liên quan của tài liệu đối với câu hỏi.

Không liệt kê những tài liệu không liên quan.

Ví dụ:

Document 1: <tóm tắt nội dung tài liệu 1>

Document 2: <tóm tắt nội dung tài liệu 2>

...

Document 10: <tóm tắt nội dung tài liệu 10>

Question: <câu hỏi>

Answer:

Doc: 9, Relevance: 7

Doc: 3, Relevance: 4

Doc: 7, Relevance: 3

Bây giờ hãy áp dụng cách làm tương tự cho dữ liệu sau: {context_str}

Question: {query_str}

Answer:

Chain-of-Thought (CoT) Re-ranking

CoT Đơn giản

Bạn là một chuyên gia phân tích và xếp hạng tài liệu. Nhiệm vụ của bạn là:

1. Phân tích truy vấn của người dùng.
2. Xếp hạng các tài liệu được cung cấp (từ 1 đến 5) theo mức độ liên quan.

[CONTEXT]

Document 1: Các mẫu điện thoại iPhone 15 Pro Max có màn hình 6.7 inch.

Document 2: Thị trường smartphone Việt Nam chứng kiến mức tăng trưởng nhẹ trong quý 3.

Document 3: So sánh chi tiết hiệu năng chip A17 Bionic trên iPhone 15 Pro Max và chip M3.

[/CONTEXT]

[QUESTION]

Phân tích và đánh giá các tài liệu liên quan đến hiệu năng của iPhone 15.

[/QUESTION]

[ANALYSIS]

Câu hỏi yêu cầu thông tin về hiệu năng và so sánh chip của iPhone 15. Tài liệu cần phải đề cập đến chip, tốc độ xử lý hoặc các bài kiểm tra benchmark.

[/ANALYSIS]

Chain-of-Thought (CoT) Re-ranking

[ANSWER]
Doc: 3, Relevance: 5
Doc: 1, Relevance: 2
Doc: 2, Relevance: 1
[/ANSWER]

[INFERENCE START]
[CONTEXT]
{context_str}
[/CONTEXT]

[QUESTION]
{query_str}
[/QUESTION]

[ANALYSIS]
(Hãy điền phần phân tích tại đây)
[/ANALYSIS]

[ANSWER]
(Hãy điền kết quả xếp hạng tại đây)
[/ANSWER]

CoT with Rationale Scoring

Bạn là một đánh giá viên tài liệu. Với mỗi tài liệu, hãy gán điểm liên quan (1-10) và viết một lý do ngắn gọn (Rationale) cho điểm đó.

[CONTEXT]

Document 1: Thảo luận về các loại chứng khoán như cổ phiếu, trái phiếu và quỹ ETF.

Document 2: Các quy định về mức thuế thu nhập cá nhân mới nhất năm 2024.

[/CONTEXT]

[QUESTION]

Các công cụ đầu tư phổ biến mà người mới bắt đầu nên tìm hiểu là gì?

[/QUESTION]

[ANSWER]

Doc: 1, Relevance: 9. Rationale: Tài liệu này trực tiếp liệt kê và giải thích các công cụ đầu tư phổ biến (cổ phiếu, trái phiếu), rất phù hợp cho người mới.

Doc: 2, Relevance: 2. Rationale: Tài liệu chỉ nói về thuế thu nhập, không trực tiếp liên quan đến các công cụ đầu tư, chỉ là thông tin hỗ trợ.

[/ANSWER]

CoT with Rationale Scoring

[INFERENCE START]

[CONTEXT]

{context_str}

[/CONTEXT]

[QUESTION]

{query_str}

[/QUESTION]

[ANSWER]

(Hãy điền kết quả xếp hạng và Rationale tại đây)

[/ANSWER]

Listwise CoT for Re-ranking

Bạn là một chuyên gia sắp xếp thông tin. Nhiệm vụ của bạn là sắp xếp lại danh sách các tài liệu (từ liên quan nhất đến ít liên quan nhất) để trả lời truy vấn. Hãy thực hiện bước Lý luận (Reasoning) để giải thích sự lựa chọn của bạn.

[CONTEXT]

Document A: Tóm tắt các yếu tố khí hậu ảnh hưởng đến cây lúa ở miền Bắc Việt Nam.

Document B: Báo cáo về sản lượng lúa ở Đồng bằng sông Cửu Long năm 2023.

Document C: Phân tích các loại sâu bệnh hại cây trồng ở khu vực Đông Nam Bộ.

[/CONTEXT]

[QUESTION]

Tìm kiếm các tài liệu liên quan đến sản lượng lúa gạo tại Việt Nam.

[/QUESTION]

[REASONING]

Truy vấn yêu cầu thông tin về SẢN LƯỢNG lúa gạo. Tài liệu B trực tiếp cung cấp báo cáo sản lượng lúa. Tài liệu A chỉ tập trung vào KHÍ HẬU ở miền Bắc. Tài liệu C nói về SÂU BỆNH. Do đó, B là liên quan nhất, A liên quan thứ hai (vì khí hậu ảnh hưởng đến sản lượng), và C ít liên quan nhất.

[/REASONING]



Listwise CoT for Re-ranking

[ANSWER]

B, A, C

[/ANSWER]

[INFERENCE START]

[CONTEXT]

{context_str}

[/CONTEXT]

[QUESTION]

{query_str}

[/QUESTION]

[REASONING]

(Hãy điền phần Lý luận so sánh toàn cục tại đây)

[/REASONING]

[ANSWER]

(Hãy điền thứ tự sắp xếp cuối cùng tại đây, ví dụ: Doc ID 1, Doc ID 3, ...)

[/ANSWER]



3. Cải thiện text embeddings với LLMs

Mô hình E5

- Các kỹ thuật retriever – reranker có một số vấn đề sau:
 - Cần các kỹ thuật để tạo ra lượng lớn cặp câu hỏi – đoạn văn bản liên quan.
 - Phụ thuộc vào tập dữ liệu thu thập thủ công, thường bị giới hạn bởi sự đa dạng của các tác vụ và phạm vi ngôn ngữ.
 - Hầu hết sử dụng bộ mã hóa dựa trên BERT, không tận dụng được các tiến bộ gần đây trong việc huấn luyện LLM tốt hơn và các kỹ thuật liên quan như mở rộng độ dài ngữ cảnh.
- Sử dụng LLMs để sinh dữ liệu nhân tạo cho nhiều tác vụ sinh biểu diễn nhúng của văn bản cho 93 ngôn ngữ
- Áp dụng chiến lược prompt hai bước:
 1. Tạo danh sách các tác vụ ứng viên
 2. Tạo dữ liệu cho các tác vụ trên.
- Fine-tune các open-source LLMs thay vì các mô hình nhỏ dựa trên BERT → mô hình E5

Sinh dữ liệu nhân tạo với GPT4

Brainstorm a list of potentially useful text retrieval tasks.

Here are a few examples for your reference:

- Provided a scientific claim as query, retrieve documents that help verify or refute the claim.
- Search for documents that answers a FAQ-style query on children's nutrition.

Please adhere to the following guidelines:

- Specify what the query is, and what the desired documents are.
- Each retrieval task should cover a wide range of queries, and should not be too specific.

Your output should always be a python list of strings only, with about 20 elements, and each element corresponds to a distinct retrieval task in one sentence. Do not explain yourself or output anything else. Be creative!



["Retrieve company's financial reports for a given stock ticker symbol.",
"Given a book name as a query, retrieve reviews, ratings and summaries of that book.",
"Search for scientific research papers supporting a medical diagnosis for a specified disease."
... (omitted for space)]

Sinh dữ liệu nhân tạo với GPT4

new session

You have been assigned a retrieval task: *{task}*

Your mission is to write one text retrieval example for this task in JSON format. The JSON object must contain the following keys:

- **"user_query"**: a string, a random user search query specified by the retrieval task.
- **"positive_document"**: a string, a relevant document for the user query.
- **"hard_negative_document"**: a string, a hard negative document that only appears relevant to the query.

Please adhere to the following guidelines:

- The "user_query" should be *{query_type}*, *{query_length}*, *{clarity}*, and diverse in topic.
- All documents should be at least *{num_words}* words long.
- Both the query and documents should be in *{language}*.
- ... *(omitted some for space)*

Your output must always be a JSON object only, do not explain yourself or output anything else. Be creative!

"user_query": "How to use Microsoft Power BI for data analysis",

"positive_document": "Microsoft Power BI is a sophisticated tool that requires time and practice to master. In this tutorial, we'll show you how to navigate Power BI ... *(omitted)* ",


"hard_negative_document": "Excel is an incredibly powerful tool for managing and analyzing large amounts of data. Our tutorial series focuses on how you...*(omitted)*" }




Finetune Mistral7B

- Tạo 500k mẫu sử dụng 150k instructions với Azure OpenAI Service 2: 25% tạo bởi GPT-35-Turbo, còn lại bởi GPT-4

distribution of task types



distribution of languages



Finetune Mistral7B

- Thêm token [EOS] vào cuối truy vấn và tài liệu, sau đó đưa vào LLM để thu được các vector nhúng cho (truy vấn, tài liệu) bằng cách lấy tầng cuối cùng của vec tơ [EOS]
- Contrastive loss

$$\min \mathbb{L} = -\log \frac{\phi(q_{\text{inst}}^+, d^+)}{\phi(q_{\text{inst}}^+, d^+) + \sum_{n_i \in \mathbb{N}} (\phi(q_{\text{inst}}^+, n_i))}$$

- Hàm đo độ tương đồng

$$\phi(q, d) = \exp\left(\frac{1}{\tau} \cos(\mathbf{h}_q, \mathbf{h}_d)\right)$$

Model finetuning and Evaluation

- Pretrained Mistral-7b checkpoint được fine-tuned 1 epoch, dùng LoRA với rank 16.
- Để giảm GPU memory, sử dụng gradient checkpoint, mixed precision training, DeepSpeed ZeRO-3.
- Training data (1.8M examples): dữ liệu nhân tạo + 13 bộ dữ liệu public
- Đánh giá: sử dụng MTEB benchmark với 15 bộ dữ liệu public
- Đánh giá 1 mô hình mất 3 ngày trên 8 V100 GPUs do cần mã hóa nhiều tài liệu
- Để hiệu quả, mặc dù mô hình có thể nhận sâu > 512 tokens, chỉ sử dụng 512 token đầu

Leaderboard: MTEB

- MTEB: Massive Text Embedding Benchmark
- Leaderboard: <https://huggingface.co/spaces/mteb/leaderboard>

Rank ▲	Model ▲	Model Size (Million Parameters) ▲	Memory Usage (GB, fp32) ▲	Embedding Dimensions ▲	Max Tokens ▲	Average (56 datasets) ▲	Classification Average (12 datasets) ▲	Clustering Average (11 datasets)
1	bge-en-icl	7111	26.49	4096	32768	71.67	88.95	57.89
2	stella_en_1.5B_v5	1543	5.75	8192	131072	71.19	87.63	57.69
3	SFR-Embedding-2_R	7111	26.49	4096	32768	70.31	89.05	56.17
4	gte-Qwen2-7B-instruct	7613	28.36	3584	131072	70.24	86.58	56.92
5	stella_en_400M_v5	435	1.62	8192	8192	70.11	86.67	56.7
6	bge-multilingual-gemma2	9242	34.43	3584	8192	69.88	88.08	54.65
7	NV-Embed-v1	7851	29.25	4096	32768	69.32	87.35	52.8
8	voyage-large-2-instruct			1024	16000	68.23	81.49	53.35
9	Linq-Embed-Mistral	7111	26.49	4096	32768	68.17	80.2	51.42
10	SFR-Embedding-Mistral	7111	26.49	4096	32768	67.56	78.33	51.67

Leaderboard: MTEB

Rank ▲	Model ▲	Model Size (Million Parameters) ▲	Memory Usage (GB, fp32) ▲	Embedding Dimensions ▲	Max Tokens ▲	Average (56 datasets) ▲	Classification Average (12 datasets) ▲	Clustering Average (11 datasets)
16	GritLM-7B	7242	26.98	4096	32768	66.76	79.46	50.61
17	e5-mistral-7b-instruct	7111	26.49	4096	32768	66.63	78.47	50.26
18	google-gecko.text-embedding-ada-002	1200	4.47	768	2048	66.31	81.17	47.48
19	IDTE					65.96	77.17	47.86
20	GritLM-8x7B	46703	173.98	4096	32768	65.66	78.53	50.14
21	gte-large-en-v1.5	434	1.62	1024	8192	65.39	77.75	47.96
22	LLM2Vec-Meta-Llama-3-supervised	7505	27.96	4096	8192	65.01	75.92	46.45
23	LLM2Vec-Mistral-supervised	7111	26.49	4096	32768	64.8	76.63	45.54
24	echo-mistral-7b-instruct-latest	7111	26.49	4096	32768	64.68	77.43	46.32

Results

# of datasets →	Class. 12	Clust. 11	PairClass. 3	Rerank 4	Retr. 15	STS 10	Summ. 1	Avg 56
<i>Unsupervised Models</i>								
Glove (Pennington et al., 2014)	57.3	27.7	70.9	43.3	21.6	61.9	28.9	42.0
SimCSE _{bert-unsup} (Gao et al., 2021)	62.5	29.0	70.3	46.5	20.3	74.3	31.2	45.5
<i>Supervised Models</i>								
SimCSE _{bert-sup} (Gao et al., 2021)	67.3	33.4	73.7	47.5	21.8	79.1	23.3	48.7
Contriever (Izacard et al., 2021)	66.7	41.1	82.5	53.1	41.9	76.5	30.4	56.0
GTR _{xxl} (Ni et al., 2022b)	67.4	42.4	86.1	56.7	48.5	78.4	30.6	59.0
Sentence-T5 _{xxl} (Ni et al., 2022a)	73.4	43.7	85.1	56.4	42.2	82.6	30.1	59.5
E5 _{large-v2} (Wang et al., 2022b)	75.2	44.5	86.0	56.6	50.6	82.1	30.2	62.3
GTE _{large} (Li et al., 2023)	73.3	46.8	85.0	59.1	52.2	83.4	31.7	63.1
BGE _{large-en-v1.5} (Xiao et al., 2023)	76.0	46.1	87.1	60.0	54.3	83.1	31.6	64.2
<i>Ours</i>								
E5 _{mistral-7b} + full data	78.5	50.3	88.3	60.2	56.9	84.6	31.4	66.6
w/ synthetic data only	78.2	50.5	86.0	59.0	46.9	81.2	31.9	63.1
w/ synthetic + msmarco	78.3	49.9	87.1	59.5	52.2	81.2	32.7	64.5

Table 1: Results on the MTEB benchmark (Muennighoff et al., 2023) (56 datasets in the English subset). The numbers are averaged for each category. Please refer to Table 17 for the scores per dataset.

Is Contrastive Pre-training Necessary?






Figure 3: Effects of contrastive pre-training.

5. Các kỹ thuật RAG tiên tiến



Query Construction





Query Translation



Routing



Retrieval




Indexing

Generation


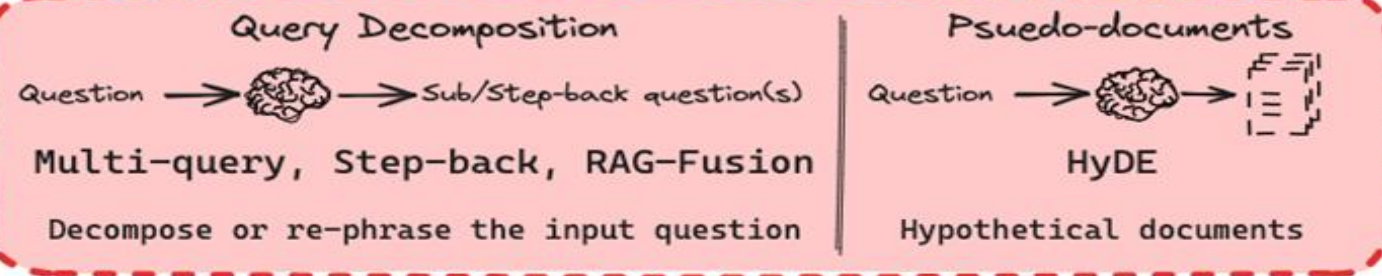


5. Các kỹ thuật RAG tiên tiến

Query Construction



Query Translation



Routing



5. Các kỹ thuật RAG tiên tiến

Question → Sub/Step-back question(s)
Multi-query, Step-back, RAG-Fusion
Decompose or re-phrase the input question

Question → hyDE
Hypothetical documents

Question

Graph DB

Re-retrieve and
(e.g., web) if r


Relational DB

Documents

Vectorstore


Routing

Logical routing



Let LLM choose DB based on the question

Semantic routing



Embed question and choose prompt based on similarity

Indexing


Chunk Optimization



Semantic Splitter

Optimize chunk size used for embedding

Multi-representation indexing



Parent Document, Dense X

Convert documents into compact retrieval units (e.g., a summary)

Specialized Embeddings



Fine-tuning, ColBERT

Domain-specific and / or advanced embedding models

Heirarchical Indexing



RAPTOR

Tree of document summarization at various abstraction levels

5. Các kỹ thuật RAG tiên tiến

