

TRUY VẤN DỮ LIỆU

Bài 10. Truy vấn đa thể thức

PGS.TS. Lê Thanh Hương
Trưởng Công nghệ thông tin và Truyền thông
Đại học Bách Khoa Hà Nội

Flexibility

Traditional computer vision systems are trained with a fixed set of **predetermined object categories**.

This **limits their flexibility**: each time we encounter a new visual concept, we need to **retrain the model** with labelled examples of this concept.

Can we train a vision model to work "zero-shot"?

Radford et al. 2021. [Learning Transferable Visual Models From Natural Language Supervision](#). *International Conference on Machine Learning*

Flexibility


Traditional computer vision systems are trained on a fixed set of **predetermined** classes. This **limits their flexibility**: each time we want to detect a new visual concept, we need to retrain the model with labelled examples of this concept.

Can we train a vision model that is flexible enough to detect any visual concept?


Natural language supervision

Prior works have shown that learning from **descriptions** rather than fixed labels can be very **data efficient**.

VirTex demonstrated data efficiency of captioning.



ConVIRT showed data efficiency of contrastive training.




Can we leverage data efficiency of natural language?


Natural language supervision

Prior works have shown that learning from **descriptions** rather than fixed labels can be very **data efficient**.

VirTex demonstrate



ConVIRT showed data



Scale

NLP systems have benefited tremendously from **scale**. T5 (Raffel et al., 2019), GPT-3 (Brown et al., 2020) etc. showed **zero-shot transfer** scale benefits.


Web scale supervision seems to surpass manual curation for NLP datasets.

Scaling up manual annotation of images is **expensive**. Thanks to **alt-text**, there are large quantities of images with text descriptions online.

Can we scale up vision training with web text?

Can we leverage data efficiency of natural language?

CLIP pre-training



Maximise similarity of image/text embeddings of the N real pairs
Minimizing similarity of $N^2 - N$ incorrect pairings


CLIP pre-training

- Huấn luyện cặp image encoder (f_I) và text encoder (f_T) bằng cách giống hệt theo phương pháp học tương phản
- Xét 1 batch gồm N cặp huấn luyện image-text (x_i, y_i)
- Hàm contrastive loss:

$$\mathcal{L}_{\text{CLIP}} := (\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I})/2. \quad \mathcal{L}_{I \rightarrow T} := -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(f_I(\mathbf{x}_i), f_T(\mathbf{y}_i))/\tau)}{\sum_{j=1}^N \exp(\text{sim}(f_I(\mathbf{x}_i), f_T(\mathbf{y}_j))/\tau)}$$

Zero-shot learning

Zero-shot image classification from captions



```

# image_encoder - ResNet or Vision Transformer
# text_encoder - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l] - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T) #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss = (loss_i + loss_t)/2

```

Figure 3. Numpy-like pseudocode for the core of an implementation of CLIP.

Creating a large enough dataset

Prior work learning with natural language has used **datasets of limited scale**

- MS COCO and Visual Genome (both $\mathcal{O}(100K)$ images)
- YFC100M ($\mathcal{O}(100M)$ images with noisy metadata, so $\mathcal{O}(15M)$ after filtering)

By contrast, strong **vision classifiers** (Mahajan et al., 2018) have benefited from training on $\mathcal{O}(3B)$ images.

To assess whether **natural language works at scale**, a new dataset is collected.

The dataset is built by searching for (image, text) pairs with **500K queries**.

The queries are formed from:

- **words** occurring at least 100 times in English Wikipedia
- **bi-grams** (with high mutual information) augment the initial queries
- **names** of wikipedia articles above a search volume threshold
- WordNet **sysnets**

Approximate **class balancing**: include up to 20K (image, text pairs) per query.

The resulting WebImageText (WIT) dataset contains **400M (image, text) pairs**.

Choosing an efficient pre-training method

The strongest computer vision systems use **significant computation** to train:

- Mahajan et al. (2018) use **19 years** of GPU time to train on instagram
- Xie et al. (2020) use **33 years** of TPUv3 time to train Noisy Student

For large-scale pre-training, **efficiency** is a key consideration.


Baseline: captioning system

inspired by VirTex

Improvement: bag of words prediction
words prediction

CLIP: **contrastive** image-text
matching


Given N image-text pairs,
CLIP predicts which of $N \times N$
possible pairs is **valid**.



- **Tính ổn định với sự thay đổi phân phối dữ liệu:**
CLIP thể hiện tính ổn định vượt trội với các thay đổi tự nhiên trong phân phối dữ liệu, nhờ vào:
 - Không phụ thuộc dữ liệu cụ thể
 - Huấn luyện quy mô lớn → không bị quá khớp

Hiệu suất với zero-shot


- Kỹ thuật tạo prompt và phương pháp ensembling cải thiện hiệu suất zero-shot. So với điểm khi chỉ sử dụng tên lớp, prompt và phương pháp ensembling giúp tăng hiệu suất phân loại zero-shot lên gần 5 điểm trung bình trên 36 bộ dữ liệu



Kỹ thuật tạo prompt

- Cung cấp ngữ cảnh
 - Tập **Oxford-IIIT Pets**, sử dụng “A photo of a [label], a type of [pet].”
 - **Food101**: “ ... a type of food”
- Sử dụng các context prompts khác nhau:
 - “A photo of a big [label]”
 - “A photo of a small [label]”

Zero-shot CLIP outperforms few-shot linear probes




Zero-shot CLIP is much more robust to distribution shift than standard ImageNet models

	Dataset Examples						ImageNet ResNet101	Zero-Shot CLIP	Δ Score
ImageNet							76.2	76.2	0%
ImageNetV2							64.3	70.1	+5.8%
ImageNet-R							37.7	88.9	+51.2%
ObjectNet							32.6	72.3	+39.7%
ImageNet Sketch							25.2	60.2	+35.0%
ImageNet-A							2.7	77.1	+74.4%

- **Task:** truy xuất hình ảnh từ cơ sở dữ liệu dựa trên 1 hình ảnh tham chiếu và 1 mô tả văn bản về các thay đổi mong muốn.
- **CIReVL:** không cần huấn luyện, tận dụng pre-trained Vision-Language Models (VLMs) và LLMs. 3 bước:
 1. **Captioning:** A pre-trained VLM (e.g., BLIP-2) generates a detailed caption describing the reference image.
 2. **Reasoning:** An LLM (e.g., GPT-3.5-turbo) takes the generated caption and the textual modification as input and produces a target caption that reflects the desired changes.
 3. **Retrieval:** A VLM like CLIP retrieves the image from the database that best matches the target caption generated by the LLM.


Karthik et al . 2024. [Vision-by-Language for Training-Free Compositional Image Retrieval](#)

Training-Free Compositional Image Retrieval through Vision-by-Language





$$I_q^t = \operatorname{argmax}_{I \in \mathcal{D}} \frac{\Psi_I(I)^\top \Psi_T(c_q^t)}{\|\Psi_I(I)\| \cdot \|\Psi_T(c_q^t)\|}$$

Training-Free Compositional Image Retrieval through Vision-by-Language



Universal Multimodal Retrieval with Multimodal LLMs



Modality-aware hard negative mining

- **Huấn luyện Mrand**: Cho query q_i với instruction $inst_i$ và các mẫu (-), tối thiểu InfoNCE loss

$$NCE = -\frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \log \frac{\exp(\eta^\theta(inst_i, q_i) \cdot \eta^\theta(c_i^+)/\tau)}{\sum_{c' \in \mathcal{D}_B} \exp(\eta^\theta(inst_i, q_i) \cdot \eta^\theta(c')/\tau)}, \quad (1)$$

where $\mathcal{D}_B = (c_1^+, c_1^-, \dots, c_{|\mathcal{B}|}^+, c_{|\mathcal{B}|}^-)$ includes all the positive and negative documents for all the queries in the mini batch $\mathcal{B}$, $\eta^\theta(\cdot) \in \mathbb{R}^d$ is a normalized vector and τ is the temperature.

- **Tạo mẫu âm**: Với mỗi q_i và $inst_i$ trong tập train, tạo 2 loại mẫu âm từ 50 kết quả tìm kiếm đầu tiên của **Mrand**:
 1. **Các mẫu âm sai phương thức** (C_i^1): các UV có rank cao hơn so với mẫu (+) đúng nhưng khác phương thức.
 2. **Các mẫu âm sai thông tin** (C_i^2): các UV có rank thấp hơn giá trị k' nhưng có phương thức mong muốn.
 - k' quá nhỏ có thể chứa mẫu dương giả, k' quá lớn sẽ khiến các mẫu âm trở nên quá dễ. Thường chọn $k'=45$

Sheng-Chieh Lin et al. 2024. [Universal Multimodal Retrieval with Multimodal LLMs](#)

Universal Multimodal Retrieval with Multimodal LLMs

Instruction: Find me an everyday image that matches the given caption. Query: A man brushes his teeth while a woman wraps in a towel.	Instruction: Identify the news-related image in line with the described event. Query: The Q Street NW entrance to the Dupont Circle Metro station.	Instruction: Find me an everyday image that matches the given caption. Query: A large tow truck towing a double decker bus.
Correct Answer		
		
Negative samples with incorrect modality		
A man brushes his teeth while a woman behind him wraps a towel around herself.	Dupont Circle metro station, Q Street escalator.	A tow truck towing a double decker bus.
A man brushing his teeth with woman in wrapping herself in a towel in the background.	Riding escalator to Q Street exit of Dupont Circle Metro.	A tow truck is in front of a double decker bus.
Negative samples with unsatisfactory information needs		
		

Continual text-to-text retrieval fine-tuning

- Fine tune NV-Embed-v1 (LLM-based retriever) on diverse public text-text retrieval tasks (MS MARCO, HotpotQA, Natural Question, StackExchange, SquAD, ...)
- **Mhard** : Lấy mẫu ngẫu nhiên các bộ ba từ cả dữ liệu huấn luyện multimodal và text-to-text retrieval training data.
- Với mỗi truy vấn q_i trong multimodal và text-to-text retrieval training data, sử dụng **Mhard** để khai thác các mẫu âm khó .
- **Mhard** không tạo ra C_i^1 nên dùng C_i^1 ở **Mrand**.

Prompting multimodal LLMs for reranking

- Prompt LLaVa-Next (Liu et al., 2024) để rerank top-10 kết quả tìm kiếm

Task	Dataset	Prompt
1. $q^{\text{txt}} \rightarrow c^{\text{img}}$	VisualNews	$\langle c^{\text{img}} \rangle \backslash n \text{News:} \langle q^{\text{txt}} \rangle \backslash n \text{Does the above News image match the News story? True or False}$
	MSCOCO	$\langle c^{\text{img}} \rangle \backslash n \text{Caption:} \langle q^{\text{txt}} \rangle \backslash n \text{Does the above daily-life image match the caption? True or False}$
	Fashion200K	$\langle c^{\text{img}} \rangle \backslash n \text{Description:} \langle q^{\text{txt}} \rangle \backslash n \text{Does the above image match the cloth style description? True or False}$
2. $q^{\text{txt}} \rightarrow c^{\text{txt}}$	WebQA	$\text{Question:} \langle q^{\text{txt}} \rangle \backslash n \text{Answer:} \langle c^{\text{txt}} \rangle \backslash n \text{Does the answer correctly answer the question? True or False}$
3. $q^{\text{txt}} \rightarrow (c^{\text{img}}, c^{\text{txt}})$	EDIS WebQA	$\text{Question:} \langle q^{\text{txt}} \rangle \backslash n \text{Answer:} \langle c^{\text{txt}} \rangle \backslash n \text{Does the answer correctly answer the question? True or False}$

Table 4: Experiments of zero-shot reranking on composed image retrieval task, CIRCO ([Baldrati et al., 2023](#)).

Model	Ret.	Rerank
MagicLens (Zhang et al., 2024)	24.9	32.4
E5-V (Jiang et al., 2024)	19.1	31.0
M^{rand} (CLIP _{SF})	12.7	31.6
M^{hard} (LLaVa-P)	29.0	37.9
M^{hard} (NV-Embed-v1)	32.4	40.9
MM-Embed	32.3	39.9

Universal Multimodal Retrieval with Multimodal LLMs

Table 5: Ablation study on fine-tuning NV-Embed-v1 w/o (✗) and w/ (✓) instructions.

Task	Dataset	zero-shot				fine-tuning	
		CLIP	LLaVa-P	NV-Embed-v1		NV-Embed-v1	
		✗	✗	✗	✓	✗	✓
1. $q^{\text{txt}} \rightarrow c^{\text{img}}$	VisualNews	40.9	11.7	15.3	17.4	33.1	38.7
	MSCOCO	55.4	58.1	64.2	59.9	76.7	82.8
	Fashion200K	8.9	2.4	4.2	3.2	12.3	15.6
4. $q^{\text{img}} \rightarrow c^{\text{txt}}$	VisualNews	42.0	6.3	6.5	5.9	29.3	37.2
	MSCOCO	79.6	66.8	70.6	68.2	88.9	93.0
	Fashion200K	7.7	2.9	4.0	3.6	12.0	16.8
5. $q^{\text{img}} \rightarrow c^{\text{img}}$	NIGHTS	25.4	28.4	29.3	27.7	31.6	30.9


Contrastive Localized Language-Image Pre-training (CLOC)

- **Hạn chế của CLIP:** CLIP căn chỉnh hình ảnh với văn bản, nhưng không đủ mạnh với các tác vụ yêu cầu hiểu ở mức vùng ảnh do image-text contrastive loss nhấn mạnh ngữ nghĩa toàn cục.
- **Giải pháp của CLOC:** học tăng cường với giám sát vùng-văn bản
 - **Promptable Embeddings:** Mục tiêu học mới cho phép bộ mã hóa hình ảnh tạo embeddings dễ dàng chuyển đổi thành biểu diễn vùng dựa trên spatial hints (bounding boxes hoặc text prompts).
 - **Promptable Region Extractor:** Một module nhẹ được thêm vào CLIP để trích xuất biểu diễn vùng dựa trên các gợi ý.
 - **VESL Captioning Pipeline:** Quy trình chú thích bán tự động, sử dụng các chú thích hình ảnh mở rộng và bộ phát hiện từ vựng mở để tạo dữ liệu cặp vùng-văn bản quy mô lớn.
 - **Mục tiêu huấn luyện:** Augmenting the CLIP loss with a region-text contrastive loss and a grounding loss.


Chen, Hong-You et al. 2024. [Contrastive Localized Language-Image Pre-Training](#)

CLOC pre-training framework


1. Pseudo-Labeling




2. Encoder Pre-Training



3a. Region-Text Tasks



3b. MLLM Fine-Tuning



- A visually-enriched and spatially-localized captioning pipeline generates pseudo-labeled bounding boxes with detailed descriptions for key image regions.
- A lightweight Prompter attached on top of the CLIP image encoder can be prompted to transform the image embedding into the region-focused feature. All parameters are trained end-to-end from scratch with our contrastive localized language-image loss on the annotated region-text datasets.
- After pre-training, (3a) region features can be generated via the Prompter for region-text tasks like object classification in a training-free fashion. (3b) The image encoder, along with the optional Prompter, can also strengthen MLLMs fine-tuning by enhancing their fine-grained image understanding capabilities

CLOC pre-training

- Huấn luyện cặp image encoder (fI) và text encoder (fT) bằng cách giống hệt theo phương pháp học tương phản
- Xét 1 batch gồm N cặp huấn luyện image-text (x_i, y_i)
- Hàm contrastive loss:

$$\mathcal{L}_{\text{CLIP}} := (\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I})/2. \quad \mathcal{L}_{I \rightarrow T} := -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(f_I(\mathbf{x}_i), f_T(\mathbf{y}_i))/\tau)}{\sum_{j=1}^N \exp(\text{sim}(f_I(\mathbf{x}_i), f_T(\mathbf{y}_j))/\tau)}$$

- Giả sử một cặp image-text (x, y) được phân tách thành các vùng ảnh $x^{(1)}, \dots, x^{(m)}$, và mỗi vùng ảnh $x^{(m)}$ có 1 chú thích chi tiết $y'^{(m)}$
- Khi đó $(x, y) = \{(\mathbf{x}^{(1)}, \mathbf{y}'^{(1)}), \dots, (\mathbf{x}^{(m)}, \mathbf{y}'^{(m)})\}$

Promptable embeddings

- Bộ mã hóa cần nhận diện được các đối tượng nhỏ chi tiết (ví dụ: "vùng này là bánh xe máy bay").
- Biểu diễn ảnh do bộ mã hóa tạo ra phải cung cấp một hiểu biết tổng thể, cho phép MLLM suy luận các mối quan hệ không gian phức tạp trong cảnh (ví dụ: "Chiếc máy bay đang hạ bộ phận bánh đáp phía trước").
- Giả thiết MLLM encoder có thể tạo ra image embedding dễ dàng chuyển đổi thành các biểu diễn vùng khi có các thông tin về vị trí.
- Region prompter $\mathbf{z} = \text{Prompter}(\mathbf{l}, f_I(\mathbf{x}))$, với $\mathbf{l}$ – biểu diễn vùng, có thể là bounding box, $f_I(\mathbf{x})$ - image embedding

$$\mathbf{z}_i^{(m)} = \text{Prompter}(\mathbf{l}_i^{(m)}, f_I(\mathbf{x}_i))$$

$\mathbf{y}_i^{(m)}$ là caption của vùng $\mathbf{l}_i^{(m)}$

- Symmetric region-text contrastive loss

$$\mathcal{L}_{R \rightarrow T} := -\frac{1}{MN} \sum_{i=1}^N \sum_{\mathbf{l}_i^{(m)} \sim \{\mathbf{l}_i\}} \log \frac{\exp(\text{sim}(\mathbf{z}_i^{(m)}, f_T(\mathbf{y}_i^{(m)})) / \tau)}{\sum_{j=1}^N \sum_{\mathbf{l}_j^{(m)} \sim \{\mathbf{l}_j\}} \exp(\text{sim}(\mathbf{z}_i^{(m)}, f_T(\mathbf{y}_j^{(m')})) / \tau)}$$

Kết quả với CLOC

- CLOC vượt trội so với CLIP trên 31 tác vụ đánh giá, bao gồm cả hình ảnh, vùng, và các chuẩn MLLM.
- Module Prompter của CLOC là yếu tố then chốt, vượt qua RoI-Align trong việc trích xuất đặc trưng vùng.
- Quy trình VESL Captioning tạo chú thích chất lượng cao hơn, cải thiện hiệu suất vùng rõ rệt.

Nhược điểm:

- **Công sức gán nhãn dữ liệu:** CLOC phụ thuộc vào dữ liệu gán nhãn vùng-văn bản quy mô lớn, đòi hỏi nhiều nỗ lực với quy trình VESL.
- **Chi phí tính toán:** Huấn luyện CLOC yêu cầu tài nguyên tính toán đáng kể, tương đương với huấn luyện CLIP thông thường.